



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA INFORMÁTICA

Trabajo fin de Grado

Grado en Ingeniería Informática – Ingeniería del Software

Explorando la complejidad y el caos en series temporales económicas

**Realizado por
Francisco Rodríguez-Carretero Roldán**

**Dirigido por
Juan Vicente Gutiérrez Santacreu**

**Departamento
Departamento de Matemática Aplicada I**

Sevilla, Julio de 2026

Resumen

Este Trabajo Fin de Grado desarrolla y valida un procedimiento computacional para analizar series temporales con herramientas de dinámica no lineal y predicción a corto plazo. El objetivo es construir una secuencia de análisis que permita detectar indicios de estructura, evaluar su utilidad predictiva frente a referencias lineales y trasladar los resultados a un modelo exportable.

La metodología se comprueba primero sobre el mapa logístico, un sistema sintético determinista y caótico conocido. Este control permite verificar si las herramientas responden de forma coherente cuando la estructura no lineal existe de manera explícita. Después se aplica el mismo enfoque a datos reales de mercado de Bitcoin en intervalos de 5 minutos, a partir de los cuales se construye una serie de volatilidad realizada. Sobre dicha serie se realiza una fase de caracterización general, que incluye análisis descriptivo, estudio de estacionariedad, correlogramas, análisis espectral y gráficos de recurrencia.

Posteriormente, se aplica un filtrado lineal y distintos contrastes de no linealidad para determinar si la dependencia observada en los datos puede explicarse mediante modelos lineales o si persiste una dinámica más compleja.

El núcleo metodológico del trabajo es la reconstrucción del espacio de estados de la serie de volatilidad mediante coordenadas retardadas. Los parámetros se seleccionan con información mutua, falsos vecinos y el método de Cao, interpretándolos como una elección operativa. Esta reconstrucción sirve después como base para estudiar medidas de complejidad dinámica y aplicar predicción local frente a modelos lineales de referencia.

En el mapa logístico, el procedimiento muestra los comportamientos esperados: estructura geométrica más nítida que en la serie financiera, divergencia positiva de trayectorias en la serie limpia y predicción local claramente efectiva a corto plazo. En Bitcoin, la persistencia, el ruido, la heterocedasticidad y los cambios de régimen obligan a interpretar los resultados con más cautela.

Como cierre predictivo se incorpora un modelo HAR-logRV compacto basado en memoria multiescala de volatilidad realizada (Corsi, 2009). Este modelo combina información de la última hora, las últimas cuatro horas y el último día, y lidera la comparación histórica sobre la muestra.

La aportación principal del trabajo es triple. Por un lado, organiza una metodología inspirada en la literatura sobre caos y dinámica no lineal, con una comprobación previa sobre una función caótica conocida. Por otro, desarrolla una implementación computacional completa para el procesamiento, análisis, visualización y evaluación empírica de una serie real. Finalmente, integra los artefactos resultantes en un MVP web desarrollado con Streamlit, capaz de cargar datos recientes, validar su calidad, calcular variables de volatilidad y generar predicciones operativas.

El enfoque adoptado permite valorar de forma rigurosa y prudente qué puede aportar la dinámica no lineal en una serie real, separando claramente la validación metodológica, la aplicación a Bitcoin, el cierre predictivo HAR y la implementación práctica del MVP.

Agradecimientos

A mis padres y a mi familia por su apoyo y comprensión.

A mi tutor, Juan Vicente Gutiérrez Santacreu, por su ayuda y orientación.

Y a mis amigos por escucharme y darme su opinión.

Índice general

Índice general	III
Índice de cuadros	VII
Índice de figuras	VIII
Índice de código	IX
1 Introducción	1
1.1 Contexto y motivación	1
1.2 Planteamiento del problema	2
1.3 Naturaleza del trabajo realizado	2
1.4 Estructura de la memoria	3
2 Definición de objetivos	5
2.1 Objetivo general	5
2.2 Objetivos específicos	5
2.3 Alcance del trabajo	6
2.4 Limitaciones del trabajo	7
2.5 Aportación principal del TFG	8
3 Antecedentes y marco teórico	9
3.1 Conceptos básicos para un lector no especialista	9
3.2 Complejidad, no linealidad y caos determinista	12
3.3 Indicios de caos en series económicas	13
3.4 Sistemas dinámicos y mapa logístico	15
3.5 Series temporales financieras y volatilidad realizada	17
3.6 Caracterización lineal de series temporales	19
3.7 Estacionariedad, heterocedasticidad y no linealidad	22
3.8 Reconstrucción del espacio de estados	24
3.9 Cuantificación de dinámicas complejas	26
3.10 Predicción local y modelos de referencia	28
3.11 Modelo HAR-logRV para volatilidad realizada	31
3.12 Relación con la tesis de referencia	32
3.13 Aportación realizada respecto a los antecedentes	33
4 Planificación, metodología de trabajo y costes	34
4.1 Organización general del proyecto	34
4.2 Fases principales del trabajo	34
4.3 Planificación temporal	34
4.4 Distribución del esfuerzo	34

4.5	Herramientas de seguimiento y desarrollo	34
4.6	Estimación de costes	34
4.7	Desviaciones respecto a la planificación inicial	34
4.8	Lecciones aprendidas durante el desarrollo	34
5	Análisis de requisitos	35
5.1	Requisitos generales del sistema	35
5.2	Requisitos conceptuales y de comunicación	35
5.3	Requisitos de datos	35
5.4	Requisitos metodológicos	35
5.5	Requisitos de la comprobación sintética	35
5.6	Requisitos funcionales del procedimiento de análisis	35
5.7	Requisitos funcionales del MVP web	35
5.8	Requisitos no funcionales	35
5.9	Criterios de validación	35
6	Diseño de la solución	36
6.1	Visión general de la solución propuesta	36
6.2	Arquitectura global del sistema	36
6.3	Diseño del procedimiento metodológico	36
6.4	Diseño de la comprobación sintética	36
6.5	Diseño de la aplicación empírica a Bitcoin	36
6.6	Diseño del flujo de datos	36
6.7	Diseño experimental y separación temporal	36
6.8	Diseño de la arquitectura del MVP web	36
6.9	Variables de entrada, salida y transformación	36
6.10	Organización del repositorio	36
7	Implementación del procedimiento de análisis	37
7.1	Estructura general del procedimiento	37
7.2	Entorno de desarrollo y herramientas utilizadas	37
7.3	Obtención y validación inicial de los datos	37
7.4	Construcción de variables y medidas de volatilidad	38
7.5	Visualización inicial y estadísticos descriptivos	38
7.6	Análisis de estacionariedad	38
7.7	Análisis de autocorrelación y espectro	38
7.8	Gráficos de recurrencia	38
7.9	Filtrado lineal mediante modelos autorregresivos	38
7.10	Contrastes de no linealidad	38
7.11	Reconstrucción del espacio de estados	38
7.12	Cuantificación de la dinámica reconstruida	38
7.13	Contrastes con barajado y datos subrogados	38
7.14	Predicción local de volatilidad	38
7.15	Experimentos de robustez y configuraciones alternativas	38
7.16	Comprobación sintética con mapa logístico	38
7.17	Modelo HAR-logRV y exportación al MVP	38
7.18	Resultado final de la validación del modelo	38
8	Resultados y discusión	39
8.1	Resultados de la comprobación sintética	39
8.2	Resultados de la aplicación empírica a Bitcoin	40
8.3	Resultados de la caracterización inicial	40

8.4	Resultados del filtrado lineal	40
8.5	Indicios de dependencia no lineal	40
8.6	Resultados de la reconstrucción del espacio de estados	40
8.7	Resultados de cuantificación dinámica	40
8.8	Resultados de predicción local	40
8.9	Comparación con modelos de referencia	40
8.10	Comparación entre configuraciones alternativas	40
8.11	Comparación final con HAR-logRV	40
8.12	Discusión: indicios frente a demostración de caos determinista	40
8.13	Interpretación global de los resultados	40
9	Implementación del MVP web	41
9.1	Objetivo del prototipo web	41
9.2	Funcionalidades implementadas	41
9.3	Arquitectura de la aplicación	41
9.4	Integración del modelo validado	41
9.5	Interfaz de usuario	41
9.6	Flujo de uso de la aplicación	41
9.7	Limitaciones del MVP	41
10	Pruebas y verificación	42
10.1	Estrategia general de pruebas	42
10.2	Validación de datos y preprocesado	42
10.3	Validación de la construcción de variables	42
10.4	Validación de los scripts del procedimiento	42
10.5	Validación de la separación train/test	42
10.6	Validación de resultados experimentales	42
10.7	Pruebas del MVP web	42
10.8	Métricas utilizadas	42
10.9	Resumen de incidencias y correcciones	42
11	Manual de usuario	43
11.1	Objetivo de la herramienta	43
11.2	Requisitos para la ejecución	43
11.3	Puesta en marcha del sistema	43
11.4	Ejecución del procedimiento de análisis	43
11.5	Uso del MVP web	43
11.6	Interpretación básica de las salidas	43
11.7	Generación de figuras, tablas e informes	43
12	Conclusiones y desarrollos futuros	44
12.1	Conclusiones generales	44
12.2	Conclusiones sobre la metodología desarrollada	44
12.3	Conclusiones sobre el mapa logístico	44
12.4	Conclusiones sobre la aplicación a Bitcoin	44
12.5	Conclusiones sobre la utilidad predictiva	44
12.6	Conclusiones sobre el MVP web	44
12.7	Limitaciones finales del trabajo	44
12.8	Desarrollos futuros	44
A	Glosario de conceptos técnicos	45
B	Relación entre fases del proyecto y capítulos de la tesis de referencia	46

<i>Índice general</i>	VI
C Detalle completo de las fases de validación	47
D Tablas de resultados extendidas	48
E Manual técnico de instalación	49
F Estructura completa del repositorio	50
Referencias	51

Índice de cuadros

3.1	Relación entre la tesis de referencia y la adaptación realizada en este trabajo. . . .	33
-----	--	----

Índice de figuras

Índice de código

Introducción

1.1– Contexto y motivación

El análisis de series temporales busca extraer información de datos ordenados en el tiempo: dependencia entre observaciones, cambios de régimen, regularidades, ruido y capacidad predictiva. En muchos problemas reales, estas señales no se explican por completo mediante modelos lineales simples, por lo que resulta útil estudiar herramientas procedentes de la dinámica no lineal. En series financieras, esta dificultad aparece con especial claridad. Los precios incorporan información de forma continua y responden a cambios de liquidez, expectativas, noticias y movimientos agregados de mercado. En este contexto, la volatilidad ocupa una posición central: no mide la dirección del precio, sino la intensidad de sus fluctuaciones.

Como aplicación empírica, Bitcoin constituye un caso adecuado para poner a prueba este tipo de herramientas. Se trata de un activo negociado de forma continua, con elevada disponibilidad de datos intradía y con episodios frecuentes de variabilidad intensa. Estas características permiten trabajar con series de alta frecuencia y construir medidas de volatilidad realizada a partir de retornos observados. En lugar de analizar directamente el nivel del precio, que suele incorporar tendencias y cambios de escala difíciles de tratar, la aplicación financiera de este trabajo se centra en la volatilidad realizada horaria obtenida a partir de velas de cinco minutos. De este modo, la variable principal resume la variabilidad reciente del activo y permite formular un problema de predicción a corto plazo.

La motivación metodológica procede del análisis de series temporales en el marco de la economía dinámica no lineal y caótica, tomando como referencia la tesis de Olmedo Fernández (Olmedo Fernández, 2001). Esta línea de trabajo plantea que una serie económica puede contener estructura temporal aunque su evolución aparente sea irregular. La distinción es importante: irregularidad no implica necesariamente azar puro, pero tampoco autoriza a afirmar la existencia de caos determinista. Entre ambos extremos se sitúa el análisis de dependencias temporales, persistencia, no linealidad, sensibilidad local y capacidad predictiva limitada.

Este Trabajo de Fin de Grado se sitúa en ese punto intermedio. Su propósito principal es desarrollar un procedimiento reproducible de análisis y predicción, comprobarlo sobre un sistema caótico conocido y aplicarlo después a una serie financiera real. Por tanto, Bitcoin no se plantea como un caso donde haya que demostrar caos, sino como una puesta en práctica exigente de las herramientas desarrolladas. La investigación se completa con la comparación frente a modelos de referencia más simples y con la construcción de un prototipo web que recoge los modelos desarro-

llados. El interés del trabajo no es únicamente matemático o estadístico, sino también computacional: se diseña un flujo reproducible, se validan datos reales, se comparan modelos y se implementa una aplicación funcional.

1.2– Planteamiento del problema

La serie principal del estudio es la volatilidad realizada transformada logarítmicamente. Esta transformación reduce la asimetría de la variable, suaviza la escala de los episodios extremos y permite trabajar con una señal más estable que el precio o que los retornos sin transformar. A partir de esta serie se plantea una cuestión empírica: si la volatilidad muestra persistencia, agrupamiento temporal y posible estructura no lineal, entonces debería ser posible detectar parte de esa estructura mediante herramientas de caracterización, reconstrucción y predicción. Sin embargo, esa hipótesis debe evaluarse con cautela, ya que una mejora predictiva frente a una referencia simple no equivale a probar la existencia de caos.

La aplicación empírica consiste en predecir la volatilidad realizada futura de Bitcoin a una hora utilizando información histórica de alta frecuencia. Para ello se parte de velas de cinco minutos del par BTCUSDT y se construyen retornos logarítmicos, medidas de volatilidad realizada pasada y una variable objetivo asociada a la volatilidad futura sobre las siguientes doce velas. La elección de este horizonte permite formular una tarea concreta: estimar la variabilidad esperada del activo durante la próxima hora, no anticipar si el precio subirá o bajará.

El estudio se organiza alrededor de varias preguntas técnicas. En primer lugar, se analiza si la serie de volatilidad realizada presenta dependencia temporal apreciable y si dicha dependencia puede explicarse por componentes lineales. En segundo lugar, se comprueba si persisten indicios de no linealidad mediante contrastes, gráficos de recurrencia, reconstrucción del espacio de estados y comparación con series barajadas o sustitutas. En tercer lugar, se evalúa si la representación reconstruida permite mejorar la predicción mediante métodos locales, comparándola con referencias como persistencia y modelos autorregresivos. Finalmente, se incorpora un modelo HAR-logRV, basado en memoria multiescala de la volatilidad realizada, como cierre práctico del bloque predictivo.

El problema tiene una dificultad adicional: los datos financieros reales combinan dependencia temporal, ruido, cambios de régimen, heterocedasticidad y posibles efectos de microestructura. Por ello, la metodología no puede limitarse a calcular indicadores aislados y extraer conclusiones fuertes. Cada resultado debe interpretarse frente a modelos de referencia y controles adecuados. Esta es una decisión central del trabajo: diferenciar entre estructura temporal, no linealidad, utilidad predictiva y demostración de caos. Solo las tres primeras conclusiones son defendibles en el caso estudiado.

1.3– Naturaleza del trabajo realizado

El trabajo realizado tiene una naturaleza mixta: matemática, experimental y de ingeniería del software. Desde el punto de vista matemático, se estudian conceptos procedentes del análisis de series temporales, la dinámica no lineal y la reconstrucción del espacio de estados. Entre las herramientas empleadas se incluyen autocorrelación, autocorrelación parcial, análisis espectral, gráficos de recurrencia, pruebas de estacionariedad, contrastes de no linealidad, información mutua, falsos vecinos, método de Cao, estimaciones aproximadas de dimensión de correlación, exponentes de Lyapunov y entropía de permutación. Estas herramientas se utilizan con una finalidad exploratoria y comparativa, no como pruebas concluyentes por separado.

Desde el punto de vista experimental, el estudio se desarrolla mediante un conjunto de fases encadenadas. Primero se validan y limpian los datos de mercado. Después se construyen las variables de volatilidad realizada y se selecciona la serie principal. A continuación se caracterizan sus propiedades temporales, se estudia su estacionariedad y se analiza la dependencia lineal. Una vez establecido ese marco, se introducen técnicas de dinámica no lineal: recurrencia, filtrado lineal, contrastes sobre residuos, reconstrucción por retardos, cuantificación de la dinámica reconstruida y comparación con series barajadas y sustitutas. Posteriormente se evalúan modelos de predicción local y se estudia la sensibilidad de sus parámetros.

Un elemento relevante del trabajo es la validación sintética mediante el mapa logístico. Esta fase permite comprobar si el procedimiento desarrollado es capaz de detectar estructura dinámica o patrones reconocibles cuando se aplica a un sistema con comportamiento caótico conocido. En la serie limpia aparece divergencia positiva de trayectorias y la predicción local mejora de forma clara a las referencias lineales; al añadir ruido, la reconstrucción se difumina y las estimaciones pierden nitidez. La comparación con Bitcoin ayuda a delimitar el alcance de los resultados: el método responde de forma clara en un entorno controlado, mientras que en la serie financiera real las conclusiones deben ser más prudentes. Esta diferencia evita confundir una herramienta de análisis con una demostración automática de caos.

La parte predictiva compara modelos con distintos grados de complejidad. Se utilizan referencias simples, modelos autorregresivos, predicción local mediante vecinos en el espacio reconstruido y un modelo HAR-logRV. Este último incorpora información de volatilidad realizada a distintas escalas temporales, por ejemplo la última hora, las últimas cuatro horas y el último día. En los resultados finales, HAR-logRV ofrece una mejora pequeña frente al modelo AR(49), pero presenta ventajas claras de simplicidad, interpretabilidad y facilidad de exportación. Por esa razón se adopta como modelo práctico recomendado para el prototipo.

La parte de ingeniería del software se concreta en dos piezas. La primera es el proceso técnico de análisis, implementado de forma reproducible y con separación entre entrenamiento, validación y prueba para evitar fuga de información. La segunda es un MVP web desarrollado con Streamlit, que integra las fuentes de datos, el cálculo automático de variables, varios modelos predictivos y visualizaciones interactivas. Este prototipo no pretende constituir una herramienta de inversión ni ofrecer señales de trading. Su función es demostrar que los resultados del estudio pueden trasladarse a una aplicación autónoma y auditable, sin depender de la ejecución manual de los scripts de investigación.

1.4– Estructura de la memoria

La memoria se organiza siguiendo la evolución natural del trabajo realizado. Tras esta introducción, el capítulo de objetivos concreta el propósito general del proyecto y descompone el trabajo en objetivos específicos relacionados con la explicación conceptual, la comprobación sintética, la aplicación a Bitcoin, la comparación de modelos y la implementación del MVP.

El capítulo de antecedentes y marco teórico presenta los conceptos necesarios para interpretar el resto del documento. Se introducen las ideas básicas de complejidad, no linealidad y caos determinista, así como las herramientas de análisis de series temporales empleadas en el estudio. También se describen la reconstrucción del espacio de estados, las métricas de cuantificación dinámica, los contrastes con series barajadas y sustitutas, la predicción local y el modelo HAR aplicado a volatilidad realizada. El objetivo de este capítulo no es reproducir de forma extensa la teoría de la dinámica no lineal, sino proporcionar el soporte mínimo para entender las decisiones metodológicas posteriores.

Los capítulos de planificación, requisitos y diseño trasladan el problema al ámbito de la ingeniería del software. En ellos se describe la organización temporal del trabajo, los requisitos funcionales y no funcionales, la arquitectura general del sistema y la separación entre el repositorio de investigación, la aplicación web y la memoria. Esta división permite distinguir entre el entorno experimental, donde se generan resultados y ficheros auxiliares, y el entorno del MVP, que debe funcionar de forma autónoma.

El capítulo de implementación del proceso de análisis expone las fases técnicas del estudio. Se explica la estructura general del procedimiento, se documenta la aplicación empírica a Bitcoin desde la validación de datos hasta la predicción, y se incluye la comprobación sintética con el mapa logístico. También se presenta el cierre mediante HAR-logRV, que conecta los resultados empíricos con un modelo final más simple y exportable.

El capítulo de resultados y discusión interpreta de manera conjunta las salidas obtenidas. Primero se resume la comprobación con el mapa logístico y después se discute la aplicación a Bitcoin. En él se comparan los modelos, se analiza la evidencia disponible sobre estructura temporal y no linealidad, y se separan explícitamente las conclusiones defendibles de aquellas que no pueden afirmarse. En particular, se argumenta que la volatilidad realizada de Bitcoin presenta persistencia, dependencia en varianza y cierta predictibilidad, pero que los resultados no permiten concluir de forma fuerte la existencia de caos determinista.

Los capítulos dedicados al MVP web, pruebas y manual de usuario describen la aplicación desarrollada, su arquitectura, sus páginas principales, los modelos integrados y las verificaciones realizadas. También se documentan sus limitaciones: el prototipo no predice dirección de mercado, no proporciona asesoramiento financiero, no estima intervalos de confianza y no debe interpretarse como una prueba de comportamiento caótico.

Por último, el capítulo de conclusiones resume las aportaciones del trabajo y plantea posibles líneas futuras. Entre ellas se encuentran la ampliación de modelos de volatilidad, la incorporación de intervalos de incertidumbre, la evaluación en otros activos, la mejora de los contrastes con series sustitutas y el despliegue más robusto de la aplicación. La memoria se completa con anexos y bibliografía, donde se recogen detalles técnicos, resultados auxiliares y referencias empleadas.

Definición de objetivos

2.1– Objetivo general

El objetivo general de este Trabajo de Fin de Grado es desarrollar y validar un procedimiento computacional para analizar series temporales desde la perspectiva de la dinámica no lineal y la predicción a corto plazo. El trabajo no parte de la idea de demostrar caos en una serie económica concreta, sino de construir una secuencia de herramientas que permita caracterizar dependencia temporal, reconstruir espacios de estados, comparar modelos predictivos y distinguir entre indicios de estructura y conclusiones no justificadas.

Para comprobar el comportamiento de estas herramientas se utilizan dos tipos de datos. En primer lugar, se emplea el mapa logístico como sistema sintético conocido, determinista, no lineal y caótico, lo que permite verificar si el procedimiento detecta señales esperables como sensibilidad a condiciones iniciales, estructura geométrica y buena predicción local a corto plazo. En segundo lugar, se aplica el mismo enfoque a un caso real: la volatilidad realizada intradía de Bitcoin, construida a partir de velas de cinco minutos del par BTCUSDT.

La serie de Bitcoin se entiende, por tanto, como una puesta en práctica de la metodología sobre datos financieros reales, no como un caso en el que se pretenda certificar caos determinista. Además del estudio técnico, el proyecto traslada los resultados a un prototipo web funcional. La aplicación permite cargar datos recientes, calcular las variables necesarias, ejecutar varios modelos predictivos y visualizar los resultados de forma interactiva. Así, el TFG combina explicación conceptual, validación empírica y desarrollo de una herramienta software autónoma.

2.2– Objetivos específicos

Para alcanzar el objetivo general se plantean los siguientes objetivos específicos:

1. Presentar de forma autocontenida los conceptos necesarios para el trabajo, incluyendo volatilidad realizada, dependencia temporal, no linealidad, reconstrucción por retardos, exponentes de Lyapunov, entropía y predicción local, sin asumir que el lector conoce previamente estas herramientas.
2. Comprobar el procedimiento sobre un sistema sintético conocido, en particular el mapa

logístico, para verificar si las herramientas responden de forma coherente cuando se aplican a una dinámica caótica controlada.

3. Aplicar el procedimiento a un caso real de datos financieros, construyendo una base de datos limpia y validada a partir de velas de cinco minutos de BTCUSDT. Esta aplicación comprueba integridad temporal, huecos, duplicados, valores nulos, valores no positivos y consistencia de precios.
4. Definir la variable principal de la aplicación empírica mediante el cálculo de retornos logarítmicos y volatilidad realizada, diferenciando entre volatilidad pasada disponible en cada instante y volatilidad futura utilizada como variable objetivo.
5. Caracterizar inicialmente la serie empírica mediante gráficos, estadísticos descriptivos, estacionariedad, autocorrelaciones y análisis espectral.
6. Estudiar la presencia de dependencia temporal e indicios de no linealidad mediante gráficos de recurrencia, filtrado lineal, análisis de residuos y contrastes complementarios.
7. Reconstruir espacios de estados a partir de las series estudiadas usando retardos temporales, información mutua, falsos vecinos y el método de Cao. Los parámetros obtenidos se interpretan como elecciones operativas, no como prueba directa de una dinámica determinista de baja dimensión.
8. Cuantificar de forma exploratoria la dinámica reconstruida mediante estimaciones aproximadas de dimensión de correlación, exponentes de Lyapunov y entropía de permutación, comparando los resultados con series barajadas y series sustitutas.
9. Evaluar la utilidad predictiva de la reconstrucción mediante métodos locales basados en vecinos y comparar su rendimiento con persistencia, modelos autorregresivos y HAR-logRV.
10. Diseñar e implementar un MVP web que integre la carga de datos, el cálculo de variables, la ejecución de modelos y la visualización de resultados, manteniendo independencia en tiempo de ejecución respecto al repositorio de investigación.
11. Documentar las limitaciones metodológicas y prácticas del estudio, especialmente en lo relativo a la interpretación de indicadores de no linealidad, la predicción financiera y el uso del prototipo como herramienta informativa.

2.3– Alcance del trabajo

El alcance del trabajo se organiza en torno a una metodología y dos contextos de uso. El primer contexto es sintético: el mapa logístico permite comprobar el comportamiento de las herramientas cuando la dinámica subyacente es conocida. El segundo contexto es empírico: la volatilidad realizada de Bitcoin en un horizonte horario, utilizando datos intradía de cinco minutos. En este segundo caso, la variable estudiada no es el precio del activo ni la dirección futura del mercado, sino una medida de variabilidad construida a partir de retornos observados. Esta delimitación centra el problema en la intensidad del movimiento, no en si el precio subirá o bajará.

Aunque el procedimiento se plantea de forma general y podría aplicarse a otras series temporales, en esta memoria solo se desarrollan completamente el control sintético con el mapa logístico y la aplicación empírica a Bitcoin. Otros activos, otras frecuencias o nuevas funciones sintéticas quedan como extensiones naturales del trabajo.

El estudio incluye una parte experimental y una parte de implementación. En la parte experimental se desarrollan las fases de validación de datos, construcción de variables, análisis descriptivo, estudio lineal, análisis no lineal, reconstrucción del espacio de estados, cuantificación dinámica, predicción local, validación sintética y comparación final de modelos. En la parte de implementación se desarrolla una aplicación web que utiliza los artefactos generados por el estudio técnico y permite ejecutar predicciones recientes sobre datos descargados de Binance, datos de ejemplo o ficheros cargados por el usuario.

El trabajo se centra en modelos interpretables y coherentes con el marco del proyecto. Se consideran referencias simples, modelos autorregresivos, métodos locales en el espacio reconstruido y HAR-logRV. No se busca construir el modelo predictivo más complejo posible, sino comparar enfoques con distinto grado de complejidad y analizar qué aporta cada uno. Esta decisión mantiene una relación clara entre teoría, experimentación y aplicación software.

Quedan dentro del alcance la validación de datos, la separación temporal entre entrenamiento, validación y prueba, la comparación out-of-sample de modelos y la documentación de las limitaciones del prototipo. También queda dentro del alcance la construcción de un sistema reproducible, con scripts, informes, figuras y ficheros auxiliares que justifican las decisiones tomadas durante el desarrollo.

2.4– Limitaciones del trabajo

El trabajo presenta varias limitaciones que deben tenerse en cuenta al interpretar sus resultados. La primera procede del propio objeto de estudio: las series financieras reales son ruidosas, no estacionarias en sentido estricto y están sometidas a cambios de régimen. Esto dificulta separar con claridad dependencia lineal, no linealidad, heterocedasticidad y efectos externos no observados.

La segunda limitación afecta a la interpretación de las herramientas de dinámica no lineal. La reconstrucción del espacio de estados, la dimensión de correlación, los exponentes de Lyapunov o la entropía de permutación pueden aportar información sobre la estructura de una serie, pero no constituyen por sí solos una demostración de caos determinista en una serie económica real. En el mapa logístico se conoce la regla generadora y, por tanto, se puede usar como control; en Bitcoin solo se pueden defender indicios y comparaciones empíricas.

La tercera limitación se refiere a la predicción. Aunque algunos modelos mejoran a referencias simples como la persistencia, las diferencias entre modelos son moderadas y deben interpretarse en términos de error estadístico, no como una ventaja operativa directa en mercado. En la aplicación a Bitcoin se predice volatilidad realizada, no rentabilidad ni dirección del precio. Por tanto, sus resultados no deben entenderse como señales de compra o venta.

La cuarta limitación está relacionada con el MVP web. El prototipo permite ejecutar modelos y visualizar resultados, pero no incorpora intervalos de confianza, gestión de riesgo, costes de transacción ni validación en tiempo real prolongada. Tampoco pretende sustituir a una plataforma profesional de análisis financiero. Su finalidad es demostrar la viabilidad técnica de integrar el estudio en una aplicación funcional y comprensible.

Por último, la aplicación empírica principal se limita a Bitcoin y a un horizonte horario concreto. Los resultados no pueden generalizarse automáticamente a otros activos, otros periodos temporales o distintas frecuencias de muestreo. Cualquier extensión requeriría repetir la validación de datos, la selección de variables, el ajuste de modelos y la evaluación out-of-sample.

2.5– Aportación principal del TFG

La aportación principal del TFG consiste en desarrollar una metodología reproducible para analizar series temporales con herramientas de dinámica no lineal y predicción, y en convertir esa metodología en una implementación software utilizable. El trabajo no se limita a aplicar modelos predictivos de forma aislada, sino que construye una secuencia que parte de la explicación conceptual, se comprueba en un sistema sintético conocido y se aplica después a datos financieros reales.

Desde el punto de vista metodológico, la aportación está en integrar herramientas inspiradas en el análisis de sistemas dinámicos en un procedimiento aplicable a series observadas. Esta adaptación se realiza con cautela: se buscan señales de dependencia, no linealidad y predictibilidad parcial, pero se evita presentar los resultados sobre Bitcoin como una prueba de caos determinista. La comparación con series barajadas, series sustitutas y un sistema sintético conocido refuerza esta lectura prudente.

Desde el punto de vista predictivo, el trabajo muestra dos resultados complementarios. En el mapa logístico, la predicción local es claramente efectiva a corto plazo porque la dinámica no lineal domina el sistema. En Bitcoin, la volatilidad realizada contiene información temporal aprovechable, aunque no necesariamente en forma de una dinámica determinista simple. Los métodos locales basados en reconstrucción mejoran a referencias básicas, pero los modelos lineales y multi-escala siguen siendo competitivos. En particular, HAR-logRV aparece como una solución práctica por su equilibrio entre rendimiento, simplicidad e interpretabilidad.

Desde el punto de vista software, la aportación consiste en trasladar el estudio técnico a una aplicación web autónoma. El MVP permite cargar datos, calcular variables, ejecutar modelos, comparar predicciones y mostrar resultados de forma accesible. Esta parte convierte el análisis en una herramienta demostrable y cierra el trabajo desde la perspectiva de la ingeniería del software.

En conjunto, el TFG aporta una aproximación integrada: explica y aplica herramientas de dinámica no lineal, las comprueba sobre una función caótica conocida, las lleva a una serie financiera real y construye una aplicación que permite utilizar parte de los resultados obtenidos. Su contribución no está en afirmar una propiedad fuerte de la volatilidad de Bitcoin, sino en mostrar qué puede analizarse, qué puede predecirse parcialmente y qué límites deben respetarse al aplicar dinámica no lineal a datos reales.

Antecedentes y marco teórico

3.1– Conceptos básicos para un lector no especialista

Una serie temporal es una sucesión de observaciones ordenadas según una variable temporal. Si se denota por x_t el valor observado en el instante t , una serie de longitud T puede escribirse como

$$\{x_t\}_{t=1}^T = x_1, x_2, \dots, x_T. \quad (3.1)$$

El subíndice t indica la posición de cada observación dentro de la secuencia. Cuando la serie está muestreada de forma regular, dos observaciones consecutivas están separadas por un intervalo fijo Δt . En ese caso, el tiempo físico asociado a la observación t puede expresarse como

$$s_t = s_0 + t\Delta t, \quad (3.2)$$

donde s_0 representa el instante inicial. En este trabajo los datos proceden de velas de cinco minutos, por lo que $\Delta t = 5$ minutos. Así, 12 observaciones corresponden a una hora, 288 observaciones a un día y 2016 observaciones a una semana.

El orden de los datos forma parte de la información de una serie temporal. En una tabla de observaciones independientes, intercambiar dos filas puede no alterar el análisis. En una serie temporal, esa operación modifica la estructura del problema, ya que el valor observado en un instante puede depender de valores anteriores. Esta dependencia se representa mediante retardos. Para un entero positivo k , el valor x_{t-k} es la observación situada k pasos antes de x_t . Por ejemplo, con datos de cinco minutos, x_{t-12} corresponde al valor observado una hora antes de x_t .

El conjunto de información disponible en un instante t puede escribirse como

$$\mathcal{F}_t = \{x_t, x_{t-1}, x_{t-2}, \dots\}. \quad (3.3)$$

Esta notación permite separar la información pasada y presente de la información futura. Cualquier predicción realizada en t debe construirse únicamente a partir de $\mathcal{F}_t$. Si durante el ajuste o la evaluación de un modelo se utiliza información posterior a t , aparece fuga de información. Este problema conduce a estimaciones artificialmente favorables, porque el modelo se beneficia de datos que no estarían disponibles en una situación real de predicción.

En el análisis de series temporales conviene distinguir entre observaciones directas y variables derivadas. En una serie financiera pueden observarse precios de apertura, máximo, mínimo, cierre, volumen o número de operaciones. A partir de estas magnitudes se calculan otras variables

diseñadas para estudiar propiedades concretas. Si P_t representa un precio observado, una variable derivada puede definirse mediante una transformación

$$z_t = g(P_t, P_{t-1}, \dots, P_{t-h}), \quad (3.4)$$

donde g es una función elegida por el investigador. Los retornos, la volatilidad realizada, las medias móviles o las variables retardadas son ejemplos de este tipo de construcción. La elección de la variable analizada forma parte de la metodología, ya que distintas transformaciones resaltan propiedades distintas de la serie.

También debe distinguirse entre variables explicativas y variable objetivo. Una variable explicativa disponible en t se construye con información pasada o presente. Una variable objetivo asociada a un horizonte futuro utiliza observaciones posteriores y sirve para entrenar o evaluar el modelo. De forma general, si h es el horizonte de predicción, puede escribirse

$$y_t^{(h)} = q(x_{t+1}, x_{t+2}, \dots, x_{t+h}), \quad (3.5)$$

donde q resume el comportamiento futuro que se desea estimar. En este TFG el horizonte principal es de 12 velas, equivalente a una hora.

El análisis de una serie temporal suele organizarse en tres tareas. La primera es la descripción de la serie. Consiste en representar sus valores y resumir propiedades básicas como nivel medio, dispersión, asimetría, colas y episodios extremos. Dos magnitudes elementales son la media muestral,

$$\bar{x} = \frac{1}{T} \sum_{t=1}^T x_t, \quad (3.6)$$

y la varianza muestral,

$$s^2 = \frac{1}{T-1} \sum_{t=1}^T (x_t - \bar{x})^2. \quad (3.7)$$

Estas medidas ofrecen una primera caracterización, aunque resultan insuficientes cuando la serie cambia de comportamiento a lo largo del tiempo o presenta periodos de variabilidad muy distintos.

La segunda tarea es la modelización. Un modelo proporciona una representación simplificada de la relación entre observaciones. En forma general, un modelo temporal puede escribirse como

$$x_t = f(x_{t-1}, x_{t-2}, \dots, x_{t-p}) + \varepsilon_t, \quad (3.8)$$

donde f describe la parte sistemática de la relación temporal, p es el número de retardos utilizados y ε_t recoge la parte no explicada por el modelo. Esta formulación no exige que el modelo reproduzca todos los mecanismos reales que generan los datos. Su valor depende de su capacidad para capturar regularidades medibles y contrastables.

La tercera tarea es la predicción. Si se desea estimar un valor futuro $y_t^{(h)}$ usando la información disponible en t , una predicción puede representarse como

$$\hat{y}_t^{(h)} = M(\mathcal{F}_t), \quad (3.9)$$

donde M es el modelo utilizado. La calidad de la predicción se evalúa comparando el valor estimado con el valor observado posteriormente. El error asociado se define como

$$e_t^{(h)} = y_t^{(h)} - \hat{y}_t^{(h)}. \quad (3.10)$$

A partir de estos errores se calculan métricas de evaluación que permiten comparar modelos sobre datos no utilizados durante el ajuste.

La dependencia temporal aparece cuando las observaciones de una serie contienen información sobre otras observaciones de la misma serie. Una forma sencilla de expresarlo es mediante la esperanza condicional:

$$\mathbb{E}[x_t \mid x_{t-1}, x_{t-2}, \dots] \neq \mathbb{E}[x_t]. \quad (3.11)$$

Esta desigualdad indica que conocer el pasado modifica la estimación esperada del presente. En series financieras, la dependencia temporal puede ser débil en los retornos y mucho más visible en medidas de variabilidad. Por esta razón, el análisis de volatilidad suele ser más informativo que el análisis directo de la dirección del precio.

La separación entre señal y ruido ayuda a interpretar los modelos. Una forma esquemática de escribir una observación es

$$x_t = s_t + \eta_t, \quad (3.12)$$

donde s_t representa una componente regular o aprovechable y η_t representa una perturbación. Esta descomposición tiene valor conceptual, pero en datos reales no suele conocerse de antemano. Una oscilación puede parecer ruido bajo un modelo simple y adquirir estructura bajo una representación más adecuada. Por ello, la distinción entre señal y ruido depende del modelo, de la escala temporal y de la información disponible.

Los modelos temporales pueden clasificarse, de forma básica, en deterministas y estocásticos. En un modelo determinista, la regla de evolución fija el estado siguiente a partir del estado actual:

$$x_{t+1} = f(x_t). \quad (3.13)$$

En un modelo estocástico interviene una perturbación aleatoria:

$$x_{t+1} = f(x_t) + \varepsilon_{t+1}. \quad (3.14)$$

La presencia de irregularidad visual en una serie no permite distinguir por sí sola entre ambas posibilidades. Un sistema determinista no lineal puede producir trayectorias muy irregulares, mientras que un modelo estocástico puede generar patrones persistentes. Esta distinción es relevante para interpretar con cautela los resultados de técnicas de dinámica no lineal.

En predicción de series temporales se trabaja normalmente con modelos de referencia. Un modelo de referencia es una alternativa sencilla que fija un nivel mínimo de comparación. En series persistentes, una referencia habitual es la persistencia:

$$\hat{y}_t^{(h)} = x_t. \quad (3.15)$$

Otra posibilidad es utilizar una media histórica o un modelo autorregresivo lineal. La comparación con estas referencias es necesaria porque un modelo más complejo solo aporta valor predictivo si mejora de forma verificable a alternativas simples.

La evaluación debe respetar el orden temporal. Si el conjunto de observaciones se divide en entrenamiento, validación y prueba, una partición coherente cumple

$$1 \leq t \leq T_{\text{train}} < T_{\text{val}} < T_{\text{test}} \leq T. \quad (3.16)$$

Los datos de entrenamiento se utilizan para ajustar el modelo, los de validación para seleccionar parámetros y los de prueba para medir el rendimiento final. Esta separación reproduce la situación real de predicción: al estimar el futuro, las observaciones posteriores al instante de decisión todavía no están disponibles.

En este TFG la predicción se entiende como una estimación a corto plazo bajo esta restricción temporal. La aplicación financiera se centra en la volatilidad realizada futura, es decir, en la intensidad de variación esperada durante un horizonte breve. La dirección del precio queda fuera del objetivo del trabajo. Esta delimitación permite estudiar una magnitud con mayor persistencia temporal y reduce la ambigüedad entre predicción de variabilidad y predicción de rentabilidad.

3.2– Complejidad, no linealidad y caos determinista

En este trabajo el término complejidad se utiliza en un sentido técnico. Una serie no se considera compleja únicamente por tener muchos datos o por presentar una gráfica difícil de interpretar. La complejidad aparece cuando el comportamiento observado no queda descrito de forma satisfactoria mediante una regla simple, estable y lineal. En series económicas y financieras esto puede manifestarse mediante dependencia del pasado, cambios de régimen, agrupamiento de episodios extremos, variabilidad no constante o relaciones que cambian según el estado del sistema.

La idea de linealidad puede formularse de manera precisa. Un operador L es lineal si, para cualesquiera valores x, y y escalares α, β , se cumple

$$L(\alpha x + \beta y) = \alpha L(x) + \beta L(y). \quad (3.17)$$

Esta propiedad recoge dos principios: proporcionalidad y superposición. La proporcionalidad indica que multiplicar la entrada por una constante multiplica la salida por esa misma constante. La superposición indica que el efecto conjunto de dos entradas puede obtenerse sumando los efectos que produciría cada una por separado.

En tiempo discreto, una evolución lineal elemental puede escribirse como

$$x_{t+1} = ax_t, \quad (3.18)$$

donde el valor futuro depende proporcionalmente del valor actual. En la práctica también se utilizan modelos afines, de la forma

$$x_{t+1} = ax_t + b, \quad (3.19)$$

que incorporan un término constante b . Aunque estrictamente una relación afín no cumple la propiedad de linealidad si $b \neq 0$, en el contexto de series temporales suele incluirse dentro de la familia de modelos lineales con constante.

Una relación no lineal no cumple la propiedad de superposición. En forma general puede escribirse como

$$x_{t+1} = f(x_t), \quad (3.20)$$

donde f no es una función lineal. Un ejemplo clásico es el mapa logístico,

$$x_{t+1} = rx_t(1 - x_t), \quad (3.21)$$

en el que el término $x_t(1 - x_t)$ introduce una interacción multiplicativa del estado consigo mismo. Esta clase de relaciones puede generar comportamientos muy distintos según el valor de los parámetros y la región del espacio en la que se encuentre el sistema.

La no linealidad puede aparecer en distintos aspectos de una serie temporal. Una posibilidad es que afecte a la media condicional, es decir, al valor esperado de la serie dado su pasado:

$$\mathbb{E}[x_t \mid \mathcal{F}_{t-1}]. \quad (3.22)$$

Otra posibilidad, especialmente relevante en series financieras, es que afecte a la varianza condicional:

$$\text{Var}(x_t \mid \mathcal{F}_{t-1}). \quad (3.23)$$

En este segundo caso, el nivel esperado de la serie puede no mostrar una dependencia clara, mientras que la intensidad de sus fluctuaciones sí depende del pasado. Este fenómeno está relacionado con la heterocedasticidad y con el agrupamiento de volatilidad: periodos de alta variabilidad tienden a estar próximos a otros periodos de alta variabilidad, y lo mismo ocurre con los periodos de baja variabilidad.

La distinción entre irregularidad, aleatoriedad y caos es esencial. Una serie irregular es aquella cuya evolución no sigue un patrón visual sencillo. Esa irregularidad puede modelizarse mediante un componente aleatorio, como ocurre en muchos modelos estocásticos. Sin embargo, también puede surgir de una regla determinista no lineal. En ese caso, el sistema no contiene ruido en su definición, pero sus trayectorias pueden parecer desordenadas.

El caos determinista describe esta situación particular: un sistema gobernado por reglas deterministas genera trayectorias irregulares, acotadas y sensibles a las condiciones iniciales. La sensibilidad a las condiciones iniciales significa que dos estados iniciales muy próximos pueden evolucionar hacia trayectorias muy diferentes. Si δ_0 representa una pequeña separación inicial entre dos trayectorias y δ_t la separación tras t pasos, una forma habitual de expresar esta divergencia es

$$|\delta_t| \approx e^{\lambda t} |\delta_0|, \quad (3.24)$$

donde λ representa una tasa media de separación. Cuando $\lambda > 0$, la distancia entre trayectorias cercanas crece exponencialmente durante el intervalo en el que la aproximación es válida. Esta propiedad limita la predicción a largo plazo, aunque puede permitir predicción local a corto plazo.

En algunos sistemas dinámicos, las trayectorias no recorren todo el espacio posible, sino que quedan confinadas en una región hacia la que el sistema tiende. Esa región se denomina atractor. En sistemas simples, el atractor puede ser un punto fijo o un ciclo periódico. En sistemas caóticos, la geometría puede ser más irregular y dar lugar a lo que se conoce como atractor extraño. En series observadas reales, sin embargo, la existencia de una nube de puntos estructurada o de patrones recurrentes no basta para afirmar que se ha identificado un atractor determinista.

La no linealidad es una condición necesaria para el caos determinista, pero no es suficiente. Muchos sistemas no lineales convergen a un equilibrio, oscilan de forma periódica o presentan comportamientos regulares. Por tanto, un contraste que detecte no linealidad no demuestra caos. Del mismo modo, una estimación positiva de divergencia local, una dimensión de correlación aparentemente baja o una mejora de predicción local deben interpretarse como indicios parciales, no como pruebas aisladas.

Esta cautela es especialmente necesaria en series financieras. Los datos de mercado combinan ruido, cambios de régimen, heterocedasticidad, dependencia temporal, efectos de liquidez y posibles errores de medición. Además, el proceso generador no se observa directamente. Por ello, al estudiar una serie como la volatilidad realizada de Bitcoin, resulta más adecuado hablar de dependencia temporal, no linealidad, estructura compatible con dinámica compleja y utilidad predictiva parcial.

La tesis de Olmedo Fernández utiliza esta distinción como punto de partida para estudiar series económicas desde la dinámica no lineal (Olmedo Fernández, 2001). Este TFG adopta esa línea metodológica, pero mantiene una interpretación conservadora. Los métodos de análisis permiten buscar indicios de comportamiento complejo y comparar modelos de predicción, pero esos indicios no autorizan, por sí solos, una afirmación de caos determinista en Bitcoin.

3.3– Indicios de caos en series económicas

En una serie económica real la identificación de caos determinista plantea dificultades que no aparecen en un sistema sintético. En un sistema construido por el investigador, como el mapa logístico, la regla de evolución es conocida y puede analizarse directamente. En una serie observada, en cambio, solo se dispone de una secuencia de datos generada por un mecanismo no observable. Si la serie se denota por $\{x_t\}_{t=1}^T$, el proceso que ha producido cada observación no se conoce de forma explícita. Por tanto, el problema no consiste en estudiar una función f dada, sino

en inferir propiedades del posible mecanismo generador a partir de una única realización finita.

Esta diferencia obliga a utilizar un lenguaje prudente. En datos económicos y financieros no suele ser posible demostrar caos en sentido estricto. Las observaciones pueden estar afectadas por ruido, errores de medida, agregación temporal, cambios institucionales, cambios de régimen, heterocedasticidad y factores externos no incluidos en la serie. Además, muchos métodos de dinámica no lineal fueron formulados bajo hipótesis más limpias que las que se cumplen en datos financieros reales: muestras largas, dinámica relativamente estable, bajo ruido y observación adecuada del sistema. Cuando estas condiciones no se cumplen plenamente, los resultados deben interpretarse como indicios.

Un indicio es una señal parcial compatible con una determinada hipótesis, pero insuficiente para establecerla por sí sola. En este contexto, pueden considerarse indicios la aparición de sensibilidad local, la existencia de estructura al reconstruir el espacio de estados, una dimensión efectiva relativamente baja en algún rango de escalas, una entropía menor que la obtenida en series barajadas o una mejora de la predicción local a corto plazo frente a modelos de referencia. Estas evidencias no tienen el mismo significado ni la misma fuerza. Su utilidad procede de la lectura conjunta y de la comparación con controles adecuados (Abarbanel, 1996; Kantz y Schreiber, 2003; Theiler, Eubank, Longtin, Galdrikian, y Farmer, 1992). La sensibilidad local se asocia a la separación de trayectorias inicialmente próximas. Si dos estados reconstruidos X_i y X_j son cercanos, puede estudiarse cómo evoluciona su distancia tras k pasos:

$$d_{ij}(k) = \|X_{i+k} - X_{j+k}\|. \quad (3.25)$$

Un crecimiento sistemático de esta distancia puede ser compatible con sensibilidad a las condiciones iniciales. Sin embargo, en una serie financiera también puede deberse a ruido, cambios de régimen o heterocedasticidad. Por ello, una pendiente positiva en una estimación tipo Lyapunov no constituye una prueba aislada de caos.

La reconstrucción del espacio de estados proporciona otro tipo de evidencia. A partir de una única serie escalar se construyen vectores retardados de la forma

$$X_t = (x_t, x_{t-\tau}, x_{t-2\tau}, \dots, x_{t-(m-1)\tau}), \quad (3.26)$$

donde τ es el retardo y m la dimensión de reconstrucción. Si la nube de puntos reconstruida muestra regiones diferenciadas, recurrencias o cierta organización geométrica, puede pensarse que la serie conserva información temporal relevante. Aun así, una nube estructurada no implica necesariamente la existencia de un atractor determinista. También puede aparecer por persistencia lineal, por cambios de volatilidad o por una distribución marginal no uniforme.

La dimensión de correlación se utiliza para estudiar cómo crece el número de puntos vecinos al aumentar una escala de distancia r . De forma simplificada, la suma de correlación puede escribirse como

$$C(r) = \frac{2}{N(N-1)} \sum_{i < j} \mathbf{1}\{\|X_i - X_j\| < r\}, \quad (3.27)$$

donde $\mathbf{1}\{\cdot\}$ vale 1 si la condición se cumple y 0 en caso contrario. Si existe una región en la que $C(r)$ sigue aproximadamente una ley de potencia,

$$C(r) \propto r^{D_2}, \quad (3.28)$$

entonces D_2 puede interpretarse como una estimación de dimensión efectiva. En datos reales, esta estimación es sensible al tamaño muestral, al ruido, a la elección de escalas y a la correlación temporal. Por tanto, una dimensión aparentemente baja solo tiene valor si se compara con controles adecuados.

La entropía proporciona una forma distinta de analizar la irregularidad. En términos generales, si una serie genera patrones π con probabilidades $p(\pi)$, una medida de entropía puede escribirse como

$$H = - \sum_{\pi} p(\pi) \log p(\pi). \quad (3.29)$$

Valores altos indican mayor diversidad de patrones; valores más bajos indican mayor regularidad. En una serie económica, una entropía menor que la de una serie barajada puede sugerir que el orden temporal contiene información. No obstante, esa diferencia no separa por sí sola no linealidad, dependencia lineal, estacionalidad o cambios de régimen.

Por este motivo son necesarios controles empíricos. Una serie barajada conserva los valores observados, pero destruye su orden temporal. Si un estadístico distingue claramente la serie original de sus versiones barajadas, puede afirmarse que el orden temporal contiene información. Este control descarta que el resultado se deba únicamente a la distribución marginal de los datos.

Las series sustitutas permiten contrastes más exigentes. Algunas se construyen para conservar aproximadamente la estructura lineal o espectral de la serie original y destruir otros aspectos de su organización temporal. Si un estadístico separa la serie original de series sustitutas que conservan parte de la dependencia lineal, la evidencia a favor de una estructura adicional es más fuerte. Si no existe separación clara, parte del comportamiento observado puede explicarse mediante dependencia lineal, heterocedasticidad o propiedades de segundo orden.

La dificultad aumenta en series financieras. La varianza suele cambiar con el tiempo y los episodios extremos tienden a concentrarse. En este caso, una señal compatible con no linealidad puede estar asociada a heterocedasticidad condicional. De forma general, esto significa que

$$\text{Var}(x_t \mid \mathcal{F}_{t-1}) \quad (3.30)$$

depende de la información pasada. Así, aunque la media condicional de los retornos sea difícil de predecir, la variabilidad futura puede contener dependencia temporal. Esta distinción es central en el estudio de volatilidad financiera.

En esta memoria se separan cuatro niveles de interpretación. El primero es la dependencia temporal: el pasado contiene información sobre el presente o sobre el futuro próximo. El segundo es la no linealidad: esa dependencia no queda explicada completamente por relaciones lineales en media. El tercero es la dinámica compleja: la serie muestra patrones compatibles con una organización temporal más rica que la de una sucesión independiente. El cuarto es el caos determinista: una propiedad fuerte de ciertos sistemas dinámicos deterministas, asociada a sensibilidad a condiciones iniciales, trayectorias acotadas e irregularidad persistente.

El análisis realizado en este TFG se mueve deliberadamente en los tres primeros niveles. Se estudia si la volatilidad realizada de Bitcoin presenta dependencia temporal, si aparecen indicios de no linealidad y si esa información tiene utilidad predictiva parcial. El cuarto nivel se reserva para sistemas donde la evidencia sea suficiente. En el caso de Bitcoin, los resultados deben interpretarse como indicios y comparaciones, no como demostración de caos determinista.

3.4– Sistemas dinámicos y mapa logístico

Un sistema dinámico es una representación matemática de la evolución de un estado a lo largo del tiempo. El estado contiene las variables necesarias para describir la situación del sistema en un instante determinado. El conjunto de todos los estados posibles recibe el nombre de espacio de estados. Cuando el sistema evoluciona, genera una sucesión de estados; esa sucesión se denomina trayectoria u órbita.

En un sistema dinámico continuo, el tiempo se considera una variable continua y la evolución suele describirse mediante ecuaciones diferenciales. Si $x(t)$ representa el estado del sistema en el instante t , una formulación general puede escribirse como

$$\frac{dx(t)}{dt} = F(x(t)), \quad (3.31)$$

donde F determina la velocidad de cambio del estado. Esta forma es habitual en modelos físicos, biológicos o económicos formulados en tiempo continuo.

En un sistema dinámico discreto, el tiempo avanza por pasos. Si x_t representa el estado en el paso t , la evolución se expresa mediante una regla de iteración:

$$x_{t+1} = f(x_t). \quad (3.32)$$

La función f transforma el estado actual en el estado siguiente. Esta formulación es adecuada cuando los datos se observan en instantes separados o cuando el propio modelo se define por iteraciones. En este TFG se trabaja con series discretas, ya que los datos financieros se registran en intervalos de cinco minutos y el sistema sintético utilizado para comprobación también se genera mediante iteraciones.

En dimensión mayor que uno, el estado deja de ser un escalar y pasa a ser un vector. Si el sistema tiene m componentes, puede escribirse como

$$X_t = (x_{1,t}, x_{2,t}, \dots, x_{m,t}) \in \mathbb{R}^m, \quad (3.33)$$

y la evolución adopta la forma

$$X_{t+1} = F(X_t). \quad (3.34)$$

Esta notación permite interpretar la dinámica como movimiento dentro de un espacio de estados. En cada instante, el sistema ocupa un punto de ese espacio; al evolucionar, va trazando una trayectoria.

El mapa logístico es uno de los ejemplos más conocidos de sistema dinámico discreto no lineal. Se define mediante la ecuación

$$x_{t+1} = rx_t(1 - x_t), \quad (3.35)$$

donde normalmente $x_t \in [0, 1]$ y r es un parámetro positivo que controla la dinámica. A pesar de su forma sencilla, este sistema puede mostrar comportamientos muy distintos según el valor de r . Para ciertos valores, la sucesión converge a un punto fijo. Para otros, oscila entre varios valores de forma periódica. Para valores suficientemente altos, como $r = 4$, puede generar una trayectoria irregular y sensible a las condiciones iniciales (May, 1976).

La no linealidad del mapa logístico procede del término $x_t(1 - x_t)$. Este término hace que el efecto de x_t sobre x_{t+1} no sea proporcional en todo el intervalo. Cuando x_t es pequeño, el producto puede aumentar en la siguiente iteración; cuando x_t se acerca a 1, el factor $1 - x_t$ reduce el valor siguiente. Esta interacción produce una dinámica que no puede entenderse como una simple relación lineal entre el estado actual y el futuro.

La sensibilidad a las condiciones iniciales puede ilustrarse comparando dos trayectorias del mapa logístico que parten de valores casi iguales. Si x_0 y $\tilde{x}_0$ son dos condiciones iniciales próximas, la separación inicial puede escribirse como

$$\delta_0 = |x_0 - \tilde{x}_0|. \quad (3.36)$$

Tras varias iteraciones, la separación será

$$\delta_t = |x_t - \tilde{x}_t|. \quad (3.37)$$

En un régimen sensible a las condiciones iniciales, una diferencia inicial muy pequeña puede crecer hasta producir trayectorias claramente distintas. Esta propiedad no implica ausencia de regla: ambas trayectorias siguen la misma ecuación. La dificultad aparece porque un pequeño error en la condición inicial se amplifica con el tiempo.

El mapa logístico tiene una función concreta dentro de esta memoria. No se utiliza como modelo de Bitcoin ni como representación de un mercado financiero. Su papel es servir como sistema de control. Al conocerse la regla generadora, puede comprobarse si el procedimiento de análisis responde de forma razonable cuando se aplica a una dinámica determinista no lineal conocida. Esta comprobación es útil antes de aplicar las mismas herramientas a una serie financiera real, donde la regla generadora no se observa y los datos contienen ruido, cambios de régimen y heterocedasticidad.

La comparación entre el mapa logístico y la serie de Bitcoin también ayuda a delimitar el alcance de las conclusiones. En el mapa logístico, el investigador conoce la ecuación que produce la serie. En Bitcoin, solo se dispone de observaciones de mercado. Por tanto, un resultado claro en el sistema sintético no autoriza a trasladar automáticamente la misma interpretación al caso financiero. La utilidad del ejemplo sintético está en validar el comportamiento del procedimiento, no en demostrar que la serie real tenga la misma naturaleza.

Esta forma de usar sistemas dinámicos sencillos como referencia conceptual está alineada con el papel que la tesis de Olmedo Fernández concede a los ejemplos deterministas antes de pasar al estudio de series económicas reales (Olmedo Fernández, 2001). En este TFG se conserva esa lógica, pero se separa explícitamente el caso controlado del caso empírico.

3.5– Series temporales financieras y volatilidad realizada

Una serie financiera de precios puede representarse como $\{P_t\}_{t=1}^T$, donde P_t es el precio observado en el instante t . En datos de velas, cada intervalo temporal contiene varias magnitudes: precio de apertura, máximo, mínimo, cierre, volumen negociado y número de operaciones. En este trabajo se utiliza principalmente el precio de cierre, ya que resume el último precio negociado dentro de cada intervalo de cinco minutos.

Aunque el precio es la variable más visible, no suele ser la más adecuada para el análisis temporal directo. Una serie de precios puede presentar tendencias, cambios de escala y niveles muy distintos a lo largo de la muestra. Además, comparar una variación de 100 unidades cuando el precio está en 10.000 con la misma variación cuando el precio está en 60.000 no tiene la misma interpretación relativa. Por este motivo, en análisis financiero se trabaja habitualmente con retornos.

El retorno logarítmico entre dos instantes consecutivos se define como

$$r_t = \log(P_t) - \log(P_{t-1}). \quad (3.38)$$

Esta expresión también puede escribirse como

$$r_t = \log\left(\frac{P_t}{P_{t-1}}\right). \quad (3.39)$$

El retorno logarítmico mide la variación relativa del precio entre dos instantes consecutivos. Para variaciones pequeñas, r_t se aproxima al retorno simple $(P_t - P_{t-1})/P_{t-1}$, pero presenta ventajas algebraicas, ya que los retornos logarítmicos acumulados en varios periodos pueden sumarse.

La volatilidad mide la intensidad de las variaciones del precio. No indica si el precio sube o baja, sino cuánto fluctúa. Dos periodos pueden tener retornos medios similares y, sin embargo,

mostrar niveles de volatilidad muy distintos. En mercados financieros esta distinción es relevante porque la incertidumbre, el riesgo y la actividad de mercado suelen estar más relacionados con la magnitud de los movimientos que con su signo.

Una forma empírica de medir la variabilidad observada es la volatilidad realizada. Para una ventana de h observaciones, se construye acumulando retornos al cuadrado. En el caso de una ventana pasada, disponible en el instante t , se define como

$$RV_t^{(h)} = \sum_{i=0}^{h-1} r_{t-i}^2. \quad (3.40)$$

Esta magnitud resume la variación acumulada durante las últimas h observaciones. En la implementación de este proyecto se utiliza la suma de retornos al cuadrado, no una media normalizada. Esta elección conserva la interpretación de variación acumulada dentro de la ventana.

La volatilidad realizada está relacionada con la idea de variación cuadrática de un proceso de precios y se utiliza de forma habitual cuando se dispone de datos de alta frecuencia (Barndorff-Nielsen y Shephard, 2002; Andersen, Bollerslev, Diebold, y Labys, 2003). En términos prácticos, permite construir una medida observable de volatilidad a partir de los retornos registrados, sin tener que tratar la volatilidad únicamente como una variable latente.

Para estabilizar la escala de la serie se aplica una transformación logarítmica. En este trabajo se define

$$v_t^{(h)} = \log \left(RV_t^{(h)} + \varepsilon \right), \quad (3.41)$$

donde $\varepsilon > 0$ es una constante pequeña introducida por estabilidad numérica. Su función es evitar problemas cuando la suma de cuadrados es muy próxima a cero. Esta transformación reduce la asimetría de la variable y suaviza la influencia de episodios extremos, lo que facilita su tratamiento estadístico.

La aplicación empírica de esta memoria se centra en ventanas de doce velas de cinco minutos. Por tanto, la ventana principal equivale a una hora:

$$h = 12. \quad (3.42)$$

La serie principal del estudio es la volatilidad realizada pasada transformada logarítmicamente, $v_t^{(12)}$. Esta variable se construye únicamente con información disponible hasta el instante t , por lo que puede utilizarse como entrada de modelos predictivos.

El objetivo predictivo es la volatilidad realizada futura sobre la hora siguiente. De forma análoga, para un horizonte de h observaciones puede definirse como

$$RV_{t,+}^{(h)} = \sum_{i=1}^h r_{t+i}^2. \quad (3.43)$$

Su transformación logarítmica viene dada por

$$y_t^{(h)} = \log \left(RV_{t,+}^{(h)} + \varepsilon \right). \quad (3.44)$$

En el caso principal del TFG, $h = 12$, de modo que $y_t^{(12)}$ representa la volatilidad realizada de la hora posterior a t . Esta variable no está disponible en el instante de predicción; se utiliza como objetivo para entrenar y evaluar los modelos.

La separación entre volatilidad pasada y volatilidad futura es metodológicamente importante. La variable $v_t^{(h)}$ resume información contenida en $\mathcal{F}_t$, mientras que $y_t^{(h)}$ depende de observaciones

posteriores. Si un modelo utilizara directa o indirectamente $y_t^{(h)}$ para predecir en t , se produciría fuga de información. Por ello, la construcción de variables debe respetar estrictamente la dirección temporal de la serie.

Una propiedad habitual de las series financieras es el agrupamiento de volatilidad. Los periodos de alta variabilidad tienden a estar próximos a otros periodos de alta variabilidad, y los periodos tranquilos tienden a agruparse. Esta propiedad puede expresarse de forma intuitiva mediante la dependencia temporal de los cuadrados de los retornos:

$$\text{Cov}(r_t^2, r_{t-k}^2) \neq 0 \quad (3.45)$$

para algunos retardos $k > 0$. Aunque los retornos r_t pueden mostrar poca autocorrelación lineal, sus cuadrados o valores absolutos suelen presentar una dependencia más marcada. Esta diferencia justifica estudiar volatilidad en lugar de dirección del precio.

El carácter persistente de la volatilidad realizada permite plantear problemas de predicción a corto plazo. La pregunta no es si el precio subirá o bajará, sino si la variabilidad futura será alta o baja en relación con el comportamiento reciente. Esta formulación es más adecuada para el objetivo del TFG, ya que la volatilidad suele contener más estructura temporal que los retornos direccionales.

La principal limitación de estas variables es el solapamiento de ventanas. Dos valores consecutivos de $RV_t^{(h)}$ comparten $h - 1$ retornos cuando la ventana se desplaza solo una observación. Por ejemplo, con $h = 12$, las ventanas de volatilidad pasada en t y $t + 1$ comparten once de los doce retornos utilizados. Este solapamiento introduce dependencia mecánica entre observaciones próximas y debe tenerse en cuenta al interpretar autocorrelaciones, contrastes y métricas predictivas.

Además de la ventana principal de una hora, en el trabajo se consideran escalas temporales más amplias para capturar memoria multiescala. Con datos de cinco minutos, las ventanas $h = 12$, $h = 48$ y $h = 288$ corresponden aproximadamente a una hora, cuatro horas y un día. Esta idea conecta con los modelos HAR de volatilidad realizada, que representan la persistencia de la volatilidad mediante componentes de distintas escalas temporales (Corsi, 2009). La formulación concreta de HAR-logRV se presenta más adelante.

3.6– Caracterización lineal de series temporales

La caracterización lineal estudia una serie temporal mediante medidas que describen su nivel, su dispersión y la relación lineal entre observaciones separadas por distintos retardos. Este análisis debe realizarse antes de aplicar herramientas no lineales, ya que una parte importante de la estructura observada en una serie puede deberse a autocorrelación, persistencia o ciclos simples (Brockwell y Davis, 2002; Box, Jenkins, Reinsel, y Ljung, 2015).

Sea $\{x_t\}_{t=1}^T$ una serie temporal. La media muestral resume el nivel promedio de la serie:

$$\bar{x} = \frac{1}{T} \sum_{t=1}^T x_t. \quad (3.46)$$

La varianza muestral mide la dispersión de los valores alrededor de esa media:

$$s^2 = \frac{1}{T-1} \sum_{t=1}^T (x_t - \bar{x})^2. \quad (3.47)$$

Estas dos magnitudes no utilizan todavía el orden temporal de las observaciones. Una serie y una permutación aleatoria de esa misma serie tendrían la misma media y la misma varianza. Para estudiar la dependencia temporal es necesario introducir medidas que comparen la serie consigo misma en distintos retardos.

La autocovarianza a retardo k mide la relación lineal entre x_t y x_{t-k} . En términos poblacionales se define como

$$\gamma(k) = \text{Cov}(x_t, x_{t-k}) = \mathbb{E}[(x_t - \mu)(x_{t-k} - \mu)], \quad (3.48)$$

donde $\mu = \mathbb{E}[x_t]$, suponiendo que la media no depende del tiempo. En una muestra finita, una estimación habitual es

$$\hat{\gamma}(k) = \frac{1}{T} \sum_{t=k+1}^T (x_t - \bar{x})(x_{t-k} - \bar{x}). \quad (3.49)$$

Si $\hat{\gamma}(k) > 0$, los valores altos tienden a aparecer junto a valores altos k pasos antes, y los valores bajos junto a valores bajos. Si $\hat{\gamma}(k) < 0$, los valores altos tienden a aparecer junto a valores bajos separados por ese retardo. Si $\hat{\gamma}(k)$ está cerca de cero, no se aprecia una relación lineal clara a ese retardo.

La autocorrelación normaliza la autocovarianza para expresarla en una escala comparable:

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)}. \quad (3.50)$$

Como $\gamma(0)$ es la varianza de la serie, $\rho(k)$ mide la intensidad de la dependencia lineal a retardo k en una escala adimensional. Su estimador muestral es

$$\hat{\rho}(k) = \frac{\hat{\gamma}(k)}{\hat{\gamma}(0)}. \quad (3.51)$$

Los valores de $\hat{\rho}(k)$ se encuentran entre -1 y 1 . Valores próximos a 1 indican fuerte persistencia lineal positiva; valores próximos a -1 indican alternancia lineal; valores próximos a cero indican ausencia de dependencia lineal apreciable a ese retardo.

La función de autocorrelación, ACF, es la representación de $\hat{\rho}(k)$ para una colección de retardos $k = 1, 2, \dots, K$. Su objetivo es mostrar cómo se relaciona la serie con su propio pasado. Una ACF que decrece lentamente indica persistencia: los valores actuales conservan memoria de observaciones anteriores durante muchos retardos. Una ACF que cae rápidamente hacia cero sugiere que la dependencia lineal desaparece pronto. Si aparecen picos en retardos concretos, puede existir una periodicidad o repetición temporal asociada a esos retardos.

En datos de cinco minutos, la interpretación de los retardos debe traducirse a tiempo físico. Un retardo $k = 12$ equivale aproximadamente a una hora; un retardo $k = 288$, a un día; y un retardo $k = 2016$, a una semana. Por tanto, un pico de autocorrelación en $k = 288$ no es solo un rasgo numérico del gráfico: puede indicar una regularidad diaria. Esta traducción es necesaria para interpretar correlogramas en series intradía.

La ACF mide dependencia lineal total entre x_t y x_{t-k} . Sin embargo, una autocorrelación alta en un retardo grande no implica necesariamente que exista una relación directa entre esos dos valores. Puede ocurrir que la dependencia aparezca inducida por retardos intermedios. Por ejemplo, si x_t depende de x_{t-1} , y x_{t-1} depende de x_{t-2} , entonces puede observarse relación entre x_t y x_{t-2} aunque el efecto directo de x_{t-2} desaparezca al tener en cuenta x_{t-1} .

La función de autocorrelación parcial, PACF, intenta separar estos efectos. La autocorrelación parcial a retardo k mide la relación lineal entre x_t y x_{t-k} después de eliminar el efecto lineal de

los retardos intermedios $x_{t-1}, x_{t-2}, \dots, x_{t-k+1}$. Una forma de definirla es mediante la regresión autorregresiva de orden k :

$$x_t = c + \phi_{k,1}x_{t-1} + \phi_{k,2}x_{t-2} + \dots + \phi_{k,k}x_{t-k} + u_t. \quad (3.52)$$

La autocorrelación parcial a retardo k es el coeficiente asociado al último retardo:

$$\alpha(k) = \phi_{k,k}. \quad (3.53)$$

Este coeficiente mide la contribución lineal adicional de x_{t-k} una vez considerados los retardos anteriores. Por eso la PACF es útil para estudiar modelos autorregresivos: ayuda a valorar cuántos retardos aportan información directa sobre el valor actual.

La diferencia entre ACF y PACF es importante. La ACF responde a la pregunta: “¿se parece la serie a sí misma k pasos antes?”. La PACF responde a una pregunta más restrictiva: “¿aporta el retardo k información lineal adicional una vez incluidos los retardos más recientes?”. En modelos autorregresivos lineales, esta distinción permite identificar dependencias directas y evitar interpretar como independientes relaciones que se explican por la propagación de retardos más cortos.

Un modelo autorregresivo lineal de orden p , denotado $AR(p)$, se escribe como

$$x_t = c + \sum_{i=1}^p \phi_i x_{t-i} + \varepsilon_t. \quad (3.54)$$

En este modelo, el valor actual se explica como combinación lineal de sus p valores anteriores. La ACF y la PACF proporcionan información preliminar sobre la memoria lineal de la serie y sobre la posible elección del orden p . No sustituyen a criterios de selección formal, como AIC o BIC, pero ayudan a interpretar la estructura temporal antes del ajuste del modelo.

Otra herramienta de caracterización lineal es el análisis espectral. Mientras la ACF estudia la serie en el dominio temporal, el análisis espectral estudia cómo se reparte la variabilidad de la serie entre distintas frecuencias. Una frecuencia alta corresponde a oscilaciones rápidas; una frecuencia baja corresponde a movimientos más lentos. Si una serie contiene ciclos aproximadamente repetidos, parte de su variabilidad se concentrará en las frecuencias asociadas a esos ciclos.

El periodograma es una estimación muestral de esa distribución de potencia por frecuencias (Brockwell y Davis, 2002; Priestley, 1981).

$$I(\omega) = \frac{1}{T} \left| \sum_{t=1}^T x_t e^{-i\omega t} \right|^2. \quad (3.55)$$

Esta expresión mide la intensidad con la que la serie contiene una oscilación asociada a la frecuencia ω . En datos financieros intradía, el periodograma puede sugerir patrones horarios, diarios o semanales. Estos patrones no deben interpretarse como periodicidad exacta, ya que los mercados no son sistemas cerrados ni perfectamente periódicos, pero sí pueden indicar regularidades temporales relevantes.

ACF, PACF y periodograma son herramientas de caracterización lineal o espectral. Permiten identificar persistencia, memoria lineal, posibles ciclos y escalas temporales relevantes. También sirven para construir modelos de referencia y para comprobar qué parte de la estructura observada puede explicarse antes de recurrir a técnicas no lineales. Esta es la razón por la que aparecen antes de la reconstrucción del espacio de estados y de los contrastes de no linealidad (Brockwell y Davis, 2002; Olmedo Fernández, 2001).

3.7– Estacionariedad, heterocedasticidad y no linealidad

Una serie temporal es débilmente estacionaria cuando sus propiedades estadísticas de primer y segundo orden no cambian con el tiempo. De forma habitual, esto se expresa exigiendo media constante, varianza constante y autocovarianza dependiente solo del retardo:

$$\mathbb{E}[x_t] = \mu, \quad \text{Var}(x_t) = \sigma^2, \quad \text{Cov}(x_t, x_{t-k}) = \gamma(k). \quad (3.56)$$

Esta definición no implica que la serie sea constante ni que sus valores sean fácilmente predecibles. Una serie estacionaria puede fluctuar de forma intensa; lo relevante es que esas fluctuaciones se produzcan alrededor de una estructura estadística estable.

La estacionariedad es importante porque muchas herramientas de series temporales se interpretan bajo la hipótesis de que la serie mantiene un comportamiento relativamente homogéneo durante la muestra. Si una serie presenta tendencia, cambios de escala o rupturas de régimen, algunas medidas pueden ser engañosas. Por ejemplo, una autocorrelación elevada puede deberse a una tendencia común y no a una relación dinámica estable entre observaciones. Del mismo modo, un contraste de no linealidad puede detectar cambios de régimen o variabilidad no constante en lugar de una estructura dinámica no lineal.

En la práctica no existe una única prueba definitiva de estacionariedad. Por este motivo suelen utilizarse contrastes con hipótesis nulas distintas. El contraste aumentado de Dickey-Fuller, ADF, parte de una regresión auxiliar en la que se estudia si la serie contiene una raíz unitaria (Dickey y Fuller, 1979). Una forma simplificada de la regresión es

$$\Delta x_t = \alpha + \beta t + \rho x_{t-1} + \sum_{i=1}^p \psi_i \Delta x_{t-i} + u_t, \quad (3.57)$$

donde $\Delta x_t = x_t - x_{t-1}$. La hipótesis de raíz unitaria se asocia al caso $\rho = 0$. Si se rechaza, se obtiene evidencia contra una forma persistente de no estacionariedad.

El contraste KPSS adopta el punto de vista contrario: su hipótesis nula es la estacionariedad alrededor de un nivel o de una tendencia (Kwiatkowski, Phillips, Schmidt, y Shin, 1992). Esta diferencia es útil. Si ADF no rechaza raíz unitaria y KPSS rechaza estacionariedad, la evidencia apunta a no estacionariedad. Si ADF rechaza raíz unitaria y KPSS no rechaza estacionariedad, la serie parece más compatible con estacionariedad. En series financieras reales, los resultados pueden ser mixtos, especialmente cuando hay cambios de régimen, episodios extremos o varianza variable. Por ello, estos contrastes deben interpretarse junto con gráficos, momentos móviles y conocimiento del problema.

La heterocedasticidad aparece cuando la varianza de una serie no es constante en el tiempo. En un modelo con residuos ε_t , la homocedasticidad exigiría

$$\text{Var}(\varepsilon_t \mid \mathcal{F}_{t-1}) = \sigma^2. \quad (3.58)$$

En cambio, si la varianza condicional depende de la información pasada, se tiene

$$\text{Var}(\varepsilon_t \mid \mathcal{F}_{t-1}) = \sigma_t^2, \quad (3.59)$$

donde σ_t^2 puede variar con t . Esta situación es habitual en series financieras: los retornos pueden tener media cercana a cero y, al mismo tiempo, alternar periodos de baja y alta variabilidad.

Los modelos ARCH formalizan esta dependencia temporal en la varianza (Engle, 1982). En su forma básica, un modelo ARCH(q) puede escribirse como

$$\varepsilon_t = \sigma_t z_t, \quad z_t \sim iid(0, 1), \quad (3.60)$$

con

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2. \quad (3.61)$$

La idea central es que errores grandes en valor absoluto tienden a ir seguidos de periodos de mayor varianza condicional. En este contexto, no se estudia solo la dependencia de x_t , sino también la dependencia de x_t^2 , $|x_t|$ o de los residuos al cuadrado.

Para separar dependencia lineal en media de otros efectos, puede ajustarse un modelo autorregresivo de orden p :

$$x_t = c + \sum_{i=1}^p \phi_i x_{t-i} + \varepsilon_t. \quad (3.62)$$

Este modelo expresa el valor actual como combinación lineal de valores pasados más un residuo. Si después del ajuste los residuos ε_t siguen mostrando estructura, esa estructura no queda explicada por la dependencia lineal incluida en el modelo. Esta idea es importante antes de aplicar contrastes de no linealidad, porque una serie con fuerte autocorrelación lineal puede provocar rechazos que no necesariamente indican dinámica no lineal.

El contraste de Ljung-Box evalúa si un conjunto de autocorrelaciones hasta cierto retardo puede considerarse conjuntamente nulo (Ljung y Box, 1978). Para un número máximo de retardos m , el estadístico se define como

$$Q = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{T-k}, \quad (3.63)$$

donde T es el tamaño muestral y $\hat{\rho}_k$ es la autocorrelación muestral a retardo k . Aplicado a residuos, el contraste permite analizar si queda dependencia lineal en media. Aplicado a residuos al cuadrado, ayuda a detectar dependencia en varianza. Esta segunda aplicación es especialmente relevante en series financieras, donde la autocorrelación de los retornos puede ser reducida mientras que la de los cuadrados resulta significativa.

La no linealidad, en este contexto, se refiere a dependencias que no quedan descritas adecuadamente por una combinación lineal de retardos. Puede aparecer en la media condicional, en la varianza condicional o en relaciones más generales entre observaciones. Por ello, rechazar un modelo lineal no identifica automáticamente un mecanismo caótico. Puede indicar heterocedasticidad, cambios de régimen, asimetrías, efectos umbral o mezcla de procesos.

El contraste BDS, introducido por Brock, Dechert y Scheinkman y desarrollado posteriormente con LeBaron, se utiliza como contraste de independencia basado en la correlación espacial de vectores construidos a partir de la serie (Brock, Dechert, Scheinkman, y LeBaron, 1996). Su lógica consiste en comparar la frecuencia con la que aparecen observaciones cercanas en dimensión m con lo que cabría esperar si la serie fuera independiente e idénticamente distribuida. De forma simplificada, se construyen vectores

$$X_t^{(m)} = (x_t, x_{t-1}, \dots, x_{t-m+1}) \quad (3.64)$$

y se calcula una suma de correlación $C_m(\varepsilon)$, que mide la proporción de pares de vectores situados a distancia menor que ε . Bajo independencia, se espera aproximadamente

$$C_m(\varepsilon) \approx C_1(\varepsilon)^m. \quad (3.65)$$

El estadístico BDS mide la desviación entre ambos términos. Si la desviación es grande, se rechaza la hipótesis de independencia.

La interpretación del BDS requiere cautela. Un rechazo puede indicar dependencia no lineal, pero también puede deberse a dependencia lineal no eliminada, heterocedasticidad, no estacionariedad o cambios de régimen. Por este motivo, en aplicaciones empíricas se suele aplicar tanto a la serie original como a residuos de un modelo lineal. Si el rechazo persiste tras el filtrado lineal, la evidencia de estructura no explicada por el modelo lineal es más fuerte. Aun así, el contraste BDS no prueba caos determinista.

En conjunto, estacionariedad, heterocedasticidad y no linealidad deben analizarse como problemas relacionados. La estacionariedad controla si la estructura estadística de la serie es razonablemente estable; la heterocedasticidad examina si la varianza cambia de forma dependiente del pasado; y los contrastes de no linealidad estudian si queda estructura más allá de relaciones lineales simples. Esta secuencia evita interpretar como caos lo que puede explicarse por persistencia lineal, varianza condicional o cambios de régimen. Esta precaución está en línea con la metodología de análisis de series económicas no lineales expuesta por Olmedo Fernández (Olmedo Fernández, 2001).

3.8– Reconstrucción del espacio de estados

La reconstrucción del espacio de estados intenta resolver una dificultad habitual en el análisis de series temporales observadas: se dispone de una sola variable medida, pero el sistema que genera la serie puede depender de más componentes. En un mercado financiero, por ejemplo, el precio o la volatilidad observada reflejan la interacción de liquidez, expectativas, volumen, información externa, actividad de distintos agentes y cambios de régimen. La mayor parte de esos factores no se observa directamente. La reconstrucción por retardos propone construir una representación aproximada del estado del sistema utilizando valores pasados de la propia serie.

Sea $\{x_t\}_{t=1}^T$ una serie escalar observada. En lugar de estudiar cada valor x_t de forma aislada, se construye un vector formado por valores retardados:

$$X_t = (x_t, x_{t-\tau}, x_{t-2\tau}, \dots, x_{t-(m-1)\tau}) . \quad (3.66)$$

El parámetro τ es el tiempo de retardo y m es la dimensión de reconstrucción. Cada vector X_t pertenece a $\mathbb{R}^m$ y representa un estado reconstruido a partir de la historia de la serie. Al variar t , los vectores X_t forman una nube de puntos en el espacio reconstruido.

La idea geométrica es sencilla. Si el valor actual de la serie no contiene por sí solo suficiente información sobre la situación del sistema, se añaden valores pasados como coordenadas adicionales. De este modo, dos instantes se consideran parecidos no solo porque tengan un valor x_t similar, sino porque presentan una configuración histórica parecida. Esta representación permite estudiar recurrencias, vecindades, trayectorias locales y predicción en un espacio de estados aproximado.

La base teórica de esta construcción procede del teorema de Takens, que establece condiciones bajo las cuales la dinámica de un sistema determinista puede reconstruirse mediante coordenadas retardadas de una variable observada (Takens, 1981). En términos intuitivos, el teorema justifica que, bajo hipótesis adecuadas, una única medición escalar puede contener información suficiente para representar la geometría de la dinámica subyacente. La tesis de Olmedo Fernández recoge esta idea dentro del estudio de reconstrucción de series temporales económicas (Olmedo Fernández, 2001).

Las condiciones ideales del teorema no se cumplen plenamente en una serie financiera. En los datos de mercado hay ruido, muestra finita, cambios de régimen, heterocedasticidad, variables omitidas y posibles errores de medición. Por esta razón, en este TFG la reconstrucción no se interpreta como recuperación exacta del verdadero espacio de estados del mercado. Se utiliza como

una representación operativa para estudiar dependencia temporal, estructura local y capacidad predictiva.

La elección del retardo τ es importante. Si τ es demasiado pequeño, las coordenadas $x_t, x_{t-\tau}, x_{t-2\tau}$ serán muy parecidas entre sí. En ese caso, el vector reconstruido contiene información redundante y la nube de puntos queda cerca de una diagonal. Si τ es demasiado grande, las coordenadas pueden perder relación dinámica y comportarse como valores casi desconectados. El objetivo es elegir un retardo que reduzca redundancia sin destruir la dependencia temporal útil.

Un criterio habitual para orientar esta elección es la información mutua media. Para dos variables discretizadas X e Y , la información mutua se define como

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}. \quad (3.67)$$

Esta cantidad mide cuánta información aporta una variable sobre la otra. Si X e Y son independientes, entonces $p(x, y) = p(x)p(y)$ y la información mutua es nula. Si existe dependencia, la información mutua toma valores positivos. En reconstrucción por retardos se calcula la información mutua entre x_t y $x_{t-\tau}$ para distintos valores de τ . Fraser y Swinney proponen usar el primer mínimo de esta función como criterio práctico para seleccionar el retardo, porque busca un compromiso entre redundancia y pérdida de relación dinámica (Fraser y Swinney, 1986).

La elección de la dimensión m plantea un problema distinto. Si m es demasiado pequeño, la reconstrucción puede comprimir la geometría del sistema y hacer que puntos alejados parezcan cercanos. Si m es demasiado grande, el espacio se vuelve más disperso, aumenta el coste computacional y las distancias entre vecinos pueden perder significado práctico. Esta dificultad es especialmente relevante en datos financieros, donde el ruido y los cambios de régimen pueden degradar la noción de vecindad.

El método de falsos vecinos se basa en una idea geométrica. Dos puntos pueden parecer cercanos en una reconstrucción de baja dimensión porque la proyección ha plegado la geometría. Al aumentar la dimensión, esos puntos dejan de ser vecinos. Si $X_t^{(m)}$ representa el vector reconstruido en dimensión m , y $X_j^{(m)}$ es uno de sus vecinos próximos, se compara la distancia en dimensión m con la distancia tras añadir una coordenada adicional:

$$X_t^{(m+1)} = (x_t, x_{t-\tau}, \dots, x_{t-m\tau}). \quad (3.68)$$

Si la distancia aumenta de forma desproporcionada al pasar de m a $m + 1$, el vecino se considera falso. A medida que m crece, el porcentaje de falsos vecinos debería disminuir si la reconstrucción despliega adecuadamente la geometría. Este método fue propuesto por Kennel, Brown y Abarbanel como un criterio práctico para determinar una dimensión mínima de reconstrucción (Kennel, Brown, y Abarbanel, 1992).

El método de Cao proporciona un contraste adicional para estudiar la dimensión de reconstrucción (Cao, 1997). Su idea es analizar cómo cambian las relaciones entre vecinos al aumentar m , utilizando cocientes de distancias entre puntos próximos. Si al incrementar la dimensión la estructura de vecindad deja de cambiar de forma relevante, se interpreta que la dimensión es suficiente para la reconstrucción. Este método resulta útil como complemento de los falsos vecinos, aunque tampoco debe interpretarse como una prueba absoluta de dimensión real en datos ruidosos.

En la práctica, también se introduce una ventana de Theiler. Esta ventana impide que puntos demasiado próximos en el tiempo sean considerados vecinos válidos. La razón es que dos observaciones consecutivas suelen parecerse por continuidad temporal o por solapamiento de información, no necesariamente porque representen estados dinámicamente equivalentes. Si se permitiesen esos vecinos inmediatos, las estimaciones de vecindad, dimensión o divergencia local podrían resultar

artificialmente optimistas. Theiler mostró que los algoritmos de dimensión pueden producir estimaciones espurias cuando se aplican sin controlar la correlación temporal en series finitas (Theiler, 1986).

Formalmente, si se busca un vecino de X_t , se excluyen candidatos X_j tales que

$$|t - j| \leq W, \quad (3.69)$$

donde W es la ventana de Theiler. Así se evita comparar un punto con observaciones casi consecutivas. Esta precaución es relevante cuando se trabaja con series de alta frecuencia y con variables construidas mediante ventanas solapadas, como ocurre con la volatilidad realizada.

La reconstrucción por retardos se usa después como base para distintos análisis. En primer lugar, permite visualizar la serie en dos o tres coordenadas retardadas. En segundo lugar, permite estudiar medidas de complejidad dinámica, como dimensión de correlación, divergencia local o entropía. En tercer lugar, permite formular predicción local: si dos estados reconstruidos son próximos, se puede comparar qué ocurrió después de estados parecidos en el pasado.

La interpretación de esta reconstrucción debe mantenerse dentro de sus límites. En un sistema sintético, como el mapa logístico, la regla generadora es conocida y la reconstrucción puede evaluarse frente a una dinámica controlada. En una serie financiera como la volatilidad realizada de Bitcoin, los parámetros τ y m deben leerse como elecciones prácticas de representación. Su selección puede estar apoyada por información mutua, falsos vecinos y el método de Cao, pero no demuestra que se haya identificado el verdadero atractor de un sistema financiero. En este trabajo, la reconstrucción se utiliza como herramienta de análisis y predicción, no como prueba directa de caos determinista.

3.9– Cuantificación de dinámicas complejas

Una vez reconstruido el espacio de estados, pueden calcularse medidas que intentan describir la geometría, la sensibilidad local o la irregularidad de las trayectorias. Estas medidas proceden de la teoría de sistemas dinámicos y aparecen en la tesis de referencia como parte de la cuantificación de dinámicas complejas (Olmedo Fernández, 2001). En este TFG se utilizan como indicadores exploratorios. Su lectura aislada no permite afirmar caos determinista en una serie financiera, pero sí ayuda a comparar la serie original con versiones de control y a estudiar si existe estructura temporal aprovechable.

La primera familia de medidas describe la geometría de la nube reconstruida. Si se dispone de N puntos $X_1, \dots, X_N$ en el espacio reconstruido, una pregunta natural es cuántos puntos quedan cerca unos de otros al variar una escala de distancia r . La suma de correlación se define como

$$C(r) = \frac{2}{N(N-1)} \sum_{i < j} \mathbf{1} \{ \|X_i - X_j\| < r \}, \quad (3.70)$$

donde $\mathbf{1}\{\cdot\}$ vale 1 si la condición se cumple y 0 en caso contrario. La función $C(r)$ mide la proporción de pares de puntos cuya distancia es menor que r . Si r es pequeño, solo se cuentan vecinos muy próximos; si r aumenta, se incorporan pares cada vez más alejados.

La dimensión de correlación se basa en estudiar cómo crece $C(r)$ cuando aumenta r . Si en un rango de escalas se observa una relación aproximada de tipo potencia,

$$C(r) \propto r^{D_2}, \quad (3.71)$$

entonces el exponente D_2 puede estimarse como la pendiente de la relación entre $\log C(r)$ y $\log r$:

$$D_2 \approx \frac{d \log C(r)}{d \log r}. \quad (3.72)$$

Esta idea fue introducida por Grassberger y Procaccia como una forma de estimar dimensiones asociadas a atractores reconstruidos (Grassberger y Procaccia, 1983). Intuitivamente, si al aumentar el radio aparecen vecinos muy rápido, la nube ocupa un espacio de mayor dimensión efectiva; si aparecen más lentamente, la estructura puede estar más concentrada.

En una aplicación empírica, la estimación de D_2 debe interpretarse con cautela. Para que la pendiente tenga sentido, debería existir una zona de escala en la que la relación logarítmica sea aproximadamente lineal. Si esa zona no aparece con claridad, no es razonable hablar de una dimensión bien determinada. Además, la estimación depende del tamaño muestral, del ruido, de la métrica de distancia, de la elección de escalas y de la correlación temporal entre puntos. Esta última cuestión es relevante: puntos muy cercanos en el tiempo pueden parecer vecinos por continuidad temporal, no por proximidad dinámica. Por ello se suele emplear una ventana de Theiler al calcular vecinos o pares de puntos (Theiler, 1986).

La segunda familia de medidas estudia la sensibilidad local. En un sistema sensible a las condiciones iniciales, dos estados inicialmente próximos pueden separarse de forma rápida. En un espacio reconstruido, si X_i y X_j son dos estados cercanos, puede observarse cómo evoluciona su distancia tras k pasos:

$$d_{ij}(k) = \|X_{i+k} - X_{j+k}\|. \quad (3.73)$$

Si la separación media crece aproximadamente de forma exponencial durante un tramo inicial, puede escribirse

$$d(k) \approx d(0)e^{\lambda k}, \quad (3.74)$$

donde λ representa una tasa media de divergencia. Tomando logaritmos se obtiene

$$\log d(k) \approx \log d(0) + \lambda k. \quad (3.75)$$

Por tanto, λ puede estimarse como la pendiente de la curva media $\log d(k)$ frente a k en una región inicial aproximadamente lineal.

El método de Rosenstein proporciona un procedimiento práctico para estimar el mayor exponente de Lyapunov a partir de series temporales reconstruidas (Rosenstein, Collins, y De Luca, 1993). La idea consiste en buscar vecinos próximos, excluir vecinos temporalmente triviales mediante una ventana de Theiler, seguir la separación entre trayectorias durante varios pasos y ajustar una pendiente en la zona inicial de divergencia. Un valor positivo de la pendiente es compatible con sensibilidad local, pero no constituye por sí solo una prueba de caos en datos financieros. El ruido, los cambios de régimen, la heterocedasticidad o una reconstrucción imperfecta también pueden producir separación rápida entre trayectorias cercanas.

La tercera familia de medidas estudia la irregularidad de la serie. La entropía de permutación mide la diversidad de patrones ordinales observados en una serie temporal (Bandt y Pompe, 2002). En lugar de utilizar directamente los valores numéricos, analiza el orden relativo de grupos de observaciones. Por ejemplo, para tres valores consecutivos (x_t, x_{t+1}, x_{t+2}) , se observa si aparecen en orden creciente, decreciente o en alguna de las restantes ordenaciones posibles. Cada ordenación define un patrón ordinal.

Si $p(\pi)$ es la frecuencia relativa del patrón ordinal π , la entropía de permutación se define como

$$H = - \sum_{\pi} p(\pi) \log p(\pi). \quad (3.76)$$

Para comparar configuraciones con distinto número de patrones posibles, se utiliza la versión normalizada:

$$H_{\text{norm}} = \frac{H}{\log(m!)}, \quad (3.77)$$

donde m es el orden de los patrones ordinales. Valores cercanos a 1 indican que los patrones aparecen con frecuencias similares, lo que corresponde a mayor irregularidad ordinal. Valores más bajos indican que ciertos patrones son más frecuentes que otros y, por tanto, que existe mayor regularidad relativa.

La entropía de permutación tiene varias ventajas prácticas. Es sencilla de calcular, no requiere estimar distancias en espacios de alta dimensión y es relativamente robusta frente a transformaciones monótonas de la serie. Sin embargo, tampoco permite identificar caos por sí sola. Una entropía menor que la de una serie aleatoria puede deberse a dependencia lineal, periodicidad aproximada, cambios de régimen o persistencia de volatilidad. Su valor debe compararse con controles adecuados.

Las series barajadas y las series sustitutas cumplen precisamente esa función de control. Una serie barajada se obtiene permutando aleatoriamente los valores observados. Este procedimiento conserva la distribución marginal de la serie, pero destruye el orden temporal. Si una métrica cambia de forma clara al barajar, puede concluirse que el orden temporal contiene información relevante. Este control es simple, pero no distingue entre dependencia lineal y no lineal.

Las series sustitutas permiten contrastes más exigentes. El método de datos sustitutos fue propuesto como una forma de contrastar si una serie contiene estructura más allá de una hipótesis nula, por ejemplo un proceso lineal transformado estáticamente (Theiler y cols., 1992). Algunas series sustitutas se generan aleatorizando fases en el dominio de Fourier, lo que conserva aproximadamente la estructura espectral lineal y destruye relaciones de fase. Otras, como AAFT, intentan conservar tanto la distribución marginal como una aproximación a la estructura lineal de la serie. Revisiones posteriores, como la de Schreiber y Schmitz, insisten en que estos contrastes deben interpretarse atendiendo a la hipótesis nula que conserva cada tipo de sustituto (Schreiber y Schmitz, 2000).

La lógica de estos controles puede resumirse de forma escalonada. Si la serie original se diferencia de sus versiones barajadas, hay evidencia de que el orden temporal importa. Si además se diferencia de series sustitutas que conservan parte de la estructura lineal, la evidencia apunta a una organización temporal que no se explica solo por la distribución marginal ni por autocorrelación lineal. Si no se observa esa separación, parte de los resultados puede estar explicada por dependencia lineal, heterocedasticidad o propiedades de segundo orden.

En conjunto, dimensión de correlación, divergencia local, entropía de permutación y contrastes con series de control permiten caracterizar la serie reconstruida desde varias perspectivas. La dimensión de correlación estudia geometría; el exponente de Lyapunov aproximado estudia sensibilidad local; la entropía de permutación estudia regularidad ordinal; y las series barajadas y sustitutas ayudan a interpretar si los valores obtenidos dependen del orden temporal. En una serie financiera, estas herramientas deben leerse como indicios complementarios, no como pruebas concluyentes de caos determinista.

3.10– Predicción local y modelos de referencia

La reconstrucción del espacio de estados también puede utilizarse con fines predictivos. La idea procede de la interpretación de la predicción como una forma indirecta de caracterizar una serie temporal: si la representación reconstruida conserva información útil sobre la dinámica, entonces estados cercanos deberían tener, al menos a corto plazo, evoluciones futuras parcialmente parecidas (Olmedo Fernández, 2001; Kantz y Schreiber, 2003; Abarbanel, 1996; Farmer y Sidorowich, 1987). Esta hipótesis no exige afirmar que el sistema sea caótico. Basta con que el espacio reconstruido agrupe situaciones con comportamiento posterior similar.

Sea X_t el estado reconstruido en el instante t , construido a partir de retardos de la serie observada. Si se desea predecir una variable futura y_t , el enfoque local busca en el conjunto de entrenamiento estados X_j próximos a X_t . La proximidad suele medirse mediante una distancia, por ejemplo la distancia euclídea:

$$d(X_t, X_j) = \|X_t - X_j\|_2. \quad (3.78)$$

A partir de esa distancia se selecciona el conjunto $N_k(X_t)$, formado por los k vecinos más cercanos de X_t dentro de los datos disponibles para entrenamiento.

El predictor local más sencillo asigna como predicción la media de los valores futuros observados después de esos vecinos. Si y_j representa el valor futuro asociado al estado vecino X_j , la predicción viene dada por

$$\hat{y}_t = \frac{1}{k} \sum_{j \in N_k(X_t)} y_j. \quad (3.79)$$

Esta formulación tiene una interpretación directa: para estimar qué ocurrirá después del estado actual, se buscan estados históricos parecidos y se promedia lo que ocurrió después de ellos. También existen variantes ponderadas, en las que los vecinos más cercanos reciben más peso:

$$\hat{y}_t = \sum_{j \in N_k(X_t)} w_j y_j, \quad \sum_{j \in N_k(X_t)} w_j = 1. \quad (3.80)$$

En este trabajo el enfoque principal se basa en medias locales simples.

El parámetro k controla el compromiso entre localidad y estabilidad. Con un valor pequeño de k , la predicción se apoya en pocos estados muy próximos. Esto puede captar relaciones locales finas, pero también aumenta la sensibilidad al ruido o a observaciones atípicas. Con un valor grande de k , la predicción se vuelve más estable, ya que promedia más casos, pero pierde especificidad local. Este comportamiento refleja el equilibrio entre varianza y sesgo: usar pocos vecinos reduce el sesgo local, pero puede aumentar la variabilidad de la estimación; usar muchos vecinos reduce la variabilidad, pero puede mezclar estados que no son realmente equivalentes.

La predicción local depende de la calidad de la reconstrucción. Si los parámetros τ y m producen una representación informativa, los vecinos en el espacio reconstruido pueden tener valor predictivo. Si la reconstrucción está dominada por ruido, por una dimensión excesiva o por cambios de régimen, la noción de vecino pierde utilidad. En espacios de dimensión alta aparece además el problema de la dispersión de los datos: las distancias tienden a ser menos informativas porque los puntos quedan más separados entre sí. Por este motivo, la dimensión de reconstrucción debe interpretarse también desde el punto de vista predictivo, no solo geométrico.

Para evitar comparaciones triviales, en predicción local se puede aplicar una ventana de Theiler o una exclusión temporal equivalente. Si se permite elegir como vecino un punto inmediatamente anterior o posterior al instante evaluado, la predicción puede beneficiarse de observaciones casi idénticas por continuidad temporal o por solapamiento de ventanas. Para evitarlo, se excluyen candidatos X_j tales que

$$|t - j| \leq W, \quad (3.81)$$

donde W es el tamaño de la ventana de exclusión. Esta precaución es especialmente relevante en series de alta frecuencia y en variables como la volatilidad realizada, donde las ventanas consecutivas comparten gran parte de sus observaciones.

La evaluación de un predictor local debe realizarse fuera de muestra. El conjunto de entrenamiento se utiliza para almacenar los estados históricos y sus valores futuros asociados. El conjunto de validación puede emplearse para seleccionar parámetros como k , τ o m . El conjunto de prueba debe reservarse para medir el rendimiento final. Esta separación temporal evita que el modelo utilice información futura de forma directa o indirecta.

Para valorar si la predicción local aporta información, debe compararse con modelos de referencia. La referencia más simple es la media histórica del entrenamiento:

$$\hat{y}_t = \bar{y}_{\text{train}}. \quad (3.82)$$

Este modelo no utiliza el estado actual; predice siempre el nivel medio observado en el tramo de entrenamiento. Aunque es muy simple, resulta útil como punto mínimo de comparación.

Otra referencia habitual en series persistentes es la persistencia. En su forma básica, asume que el valor futuro será igual al último valor disponible:

$$\hat{y}_{t+h} = x_t. \quad (3.83)$$

En la aplicación a volatilidad realizada, esta referencia equivale a usar la volatilidad realizada reciente como predicción de la volatilidad futura. Si una serie tiene fuerte persistencia, esta referencia puede ser difícil de superar.

También se emplean modelos autorregresivos lineales como referencia. Un modelo $AR(p)$ tiene la forma

$$x_t = c + \sum_{i=1}^p \phi_i x_{t-i} + \varepsilon_t. \quad (3.84)$$

Este modelo captura dependencia lineal en media mediante una combinación de retardos. Su papel en este trabajo es servir como comparación frente a los métodos locales en el espacio reconstruido. Si un método no lineal no mejora a una referencia autorregresiva, su ventaja predictiva no queda justificada aunque pueda ser útil como herramienta de análisis.

El rendimiento predictivo se mide comparando los valores observados y_i con las predicciones $\hat{y}_i$. Una métrica habitual es el error absoluto medio:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|. \quad (3.85)$$

El MAE mide el tamaño medio del error en la misma escala que la variable objetivo. Al usar valor absoluto, penaliza de forma lineal las desviaciones.

Otra métrica frecuente es la raíz del error cuadrático medio:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (3.86)$$

El $RMSE$ penaliza más los errores grandes porque eleva las diferencias al cuadrado antes de promediarlas. Por esta razón puede ser más sensible a episodios extremos que el MAE .

También puede utilizarse un coeficiente de determinación fuera de muestra. En este trabajo se expresa como

$$R_{\text{OOS}}^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y}_{\text{train}})^2}. \quad (3.87)$$

El denominador compara contra una predicción constante basada en la media del entrenamiento. Si $R_{\text{OOS}}^2 > 0$, el modelo mejora esa referencia constante. Si $R_{\text{OOS}}^2 < 0$, el modelo predice peor que usar la media histórica del entrenamiento.

Una mejora predictiva moderada no prueba caos determinista. Indica que el modelo ha capturado alguna regularidad útil bajo una partición temporal concreta. En datos financieros, esa regularidad puede proceder de persistencia, heterocedasticidad, memoria multiescala o cambios de régimen. Por ello, la predicción local se interpreta junto con los modelos de referencia y con el resto de indicadores del análisis. Su valor principal es comprobar si la reconstrucción del espacio de estados contiene información práctica para anticipar parcialmente la volatilidad futura.

3.11– Modelo HAR-logRV para volatilidad realizada

El modelo HAR, acrónimo de *Heterogeneous Autoregressive model*, es un modelo diseñado para describir y predecir volatilidad realizada a partir de información agregada en varias escalas temporales. Fue propuesto originalmente para capturar la persistencia de la volatilidad mediante una estructura sencilla e interpretable (Corsi, 2009). Su motivación está relacionada con la heterogeneidad de horizontes en los mercados financieros: distintos participantes operan y reaccionan en escalas temporales diferentes (Müller y cols., 1997). Algunos agentes reaccionan a movimientos muy recientes, mientras que otros toman decisiones considerando horizontes más amplios. Como consecuencia, la volatilidad futura puede depender simultáneamente de medidas de volatilidad de corto, medio y mayor plazo. El modelo HAR no pertenece a la familia de métodos de dinámica caótica. Tampoco reconstruye un espacio de estados ni busca identificar un atractor. Su función en este trabajo es distinta: proporcionar un modelo de referencia multiescala para volatilidad realizada. Esta diferencia es relevante porque permite separar dos objetivos. Por un lado, el análisis de reconstrucción y cuantificación estudia si la serie presenta estructura compatible con dinámica compleja. Por otro, HAR-logRV ofrece una formulación práctica para explotar la persistencia temporal de la volatilidad.

En su forma general, un modelo HAR para volatilidad realizada expresa la volatilidad futura como combinación lineal de volatilidades realizadas calculadas en distintas ventanas. En este TFG se trabaja con la transformación logarítmica de la volatilidad realizada. Siguiendo la notación introducida anteriormente, sea

$$v_t^{(h)} = \log \left(RV_t^{(h)} + \varepsilon \right) \quad (3.88)$$

la volatilidad realizada pasada transformada logarítmicamente para una ventana de h observaciones. El uso de volatilidad realizada se apoya en la literatura de datos financieros de alta frecuencia, donde esta magnitud se emplea como medida observable de variabilidad y como base para modelos de predicción (Andersen y cols., 2003). La variable objetivo para el horizonte principal se denota por

$$y_t^{(12)} = \log \left(RV_{t,+}^{(12)} + \varepsilon \right), \quad (3.89)$$

donde $RV_{t,+}^{(12)}$ representa la volatilidad realizada de las doce velas posteriores al instante t .

Adaptado a datos de cinco minutos, el modelo HAR-logRV utilizado en este trabajo puede escribirse como

$$y_t^{(12)} = \beta_0 + \beta_1 v_t^{(12)} + \beta_2 v_t^{(48)} + \beta_3 v_t^{(288)} + u_t. \quad (3.90)$$

En esta ecuación, $v_t^{(12)}$ resume la volatilidad realizada de la última hora, $v_t^{(48)}$ resume la volatilidad realizada de las últimas cuatro horas y $v_t^{(288)}$ resume la volatilidad realizada del último día completo. El término u_t recoge la parte de la volatilidad futura que no queda explicada por esas tres escalas.

La elección de estas ventanas responde a la frecuencia de los datos. Al trabajar con velas de cinco minutos, doce observaciones equivalen a una hora:

$$12 \times 5 \text{ minutos} = 60 \text{ minutos}. \quad (3.91)$$

Del mismo modo, cuarenta y ocho observaciones equivalen a cuatro horas, y 288 observaciones equivalen a un día:

$$48 \times 5 \text{ minutos} = 240 \text{ minutos}, \quad 288 \times 5 \text{ minutos} = 1440 \text{ minutos}. \quad (3.92)$$

Estas escalas permiten representar memoria reciente, memoria intradía más amplia y memoria diaria dentro de un modelo lineal compacto.

Los coeficientes del modelo tienen una interpretación directa. El parámetro β_1 mide la relación entre la volatilidad realizada más reciente y la volatilidad futura. El coeficiente β_2 recoge la contribución de una ventana intradía más amplia. El coeficiente β_3 incorpora información del último día. Si estos coeficientes son positivos, la interpretación habitual es que niveles altos de volatilidad pasada en esas escalas se asocian con niveles altos de volatilidad futura.

El ajuste del modelo puede realizarse mediante mínimos cuadrados ordinarios. Dado un conjunto de observaciones de entrenamiento, los coeficientes se eligen minimizando la suma de errores cuadráticos:

$$\min_{\beta_0, \beta_1, \beta_2, \beta_3} \sum_{t \in \mathcal{T}_{\text{train}}} \left(y_t^{(12)} - \beta_0 - \beta_1 v_t^{(12)} - \beta_2 v_t^{(48)} - \beta_3 v_t^{(288)} \right)^2. \quad (3.93)$$

La estimación debe hacerse únicamente con datos de entrenamiento. Una vez ajustados los coeficientes, el modelo se evalúa sobre tramos posteriores sin utilizar información futura en el ajuste.

El modelo HAR-logRV se diferencia de un modelo autorregresivo clásico en la forma de resumir el pasado. Un modelo AR(p) utiliza valores retardados concretos:

$$x_t = c + \sum_{i=1}^p \phi_i x_{t-i} + \varepsilon_t. \quad (3.94)$$

En cambio, HAR utiliza agregados de volatilidad sobre ventanas de distinta longitud. Esta decisión reduce el número de parámetros y facilita la interpretación. En lugar de introducir muchos retardos individuales, el modelo resume la información pasada en escalas temporales relevantes.

Esta simplicidad es una de las razones por las que HAR-logRV resulta adecuado como cierre predictivo práctico. El modelo es rápido de ajustar, sus coeficientes son interpretables y su implementación en una aplicación web es directa. Además, al trabajar con variables ya construidas a partir de volatilidad realizada, mantiene una conexión clara con el fenómeno financiero estudiado: la persistencia de la variabilidad.

El papel de HAR-logRV en esta memoria debe entenderse con precisión. No se utiliza como evidencia de caos ni como sustituto del análisis no lineal. Se utiliza como modelo práctico de comparación frente a persistencia, modelos autorregresivos y predicción local en el espacio reconstruido. Sus resultados empíricos se discuten en capítulos posteriores. En este marco teórico basta con fijar su significado: un modelo lineal multiescala para volatilidad realizada, útil por su equilibrio entre sencillez, interpretabilidad y capacidad predictiva.

3.12– Relación con la tesis de referencia

La tesis de Olmedo Fernández proporciona el marco metodológico general de este trabajo (Olmedo Fernández, 2001). Su recorrido parte de conceptos de determinismo, azar, complejidad y caos; continúa con sistemas dinámicos y herramientas de caracterización; introduce la reconstrucción del espacio de estados; estudia estacionariedad y no linealidad; y finalmente aborda cuantificación y predicción en una aplicación económica.

Este TFG no reproduce la tesis ni intenta trasladarla punto por punto. Toma su lógica de trabajo y la adapta a un problema computacional actual. La diferencia principal está en el enfoque: aquí se desarrolla un procedimiento reproducible, se comprueba primero sobre un sistema sintético conocido y después se aplica a una serie financiera de alta frecuencia. La tesis trabaja con desempleo mensual en España; este trabajo usa volatilidad realizada de Bitcoin construida a partir de velas de cinco minutos.

Elemento en Olmedo	Adaptación en este TFG
Marco de complejidad, no linealidad y caos	Lectura prudente orientada a indicios, no a demostración de caos en BTC
Caracterización de series temporales	Validación, visualización, ACF, PACF, periodograma y recurrencia sobre volatilidad realizada
Reconstrucción por retardos	Selección operativa de τ y m con información mutua, falsos vecinos y Cao
Cuantificación dinámica	Dimensión de correlación, Lyapunov y entropía comparadas con series barajadas y series sustitutas
Predicción	Comparación fuera de muestra con persistencia, modelos autorregresivos, predicción local y HAR-logRV
Aplicación empírica económica	Aplicación financiera de alta frecuencia y prototipo web autónomo

Cuadro 3.1: Relación entre la tesis de referencia y la adaptación realizada en este trabajo.

La adaptación también introduce controles propios de un proyecto de ingeniería: separación temporal entre entrenamiento, validación y prueba, validación explícita de datos, generación de artefactos reproducibles y construcción de un MVP web. Esta parte no aparece en la tesis de referencia, pero resulta coherente con la naturaleza del grado y con el objetivo de convertir el análisis en una herramienta utilizable.

3.13– Aportación realizada respecto a los antecedentes

La aportación de este TFG no consiste en proponer una nueva teoría de caos ni en afirmar una propiedad fuerte sobre Bitcoin. La aportación está en integrar y adaptar una metodología de análisis de series temporales mediante dinámica no lineal a un caso financiero de alta frecuencia, manteniendo una lectura prudente de los resultados.

El trabajo aporta un procedimiento reproducible que empieza con validación de datos, construcción de variables y caracterización lineal; continúa con contrastes de dependencia, reconstrucción por retardos y cuantificación exploratoria; y termina con comparación predictiva y exportación a una aplicación web. La comprobación con el mapa logístico permite observar cómo responde el procedimiento ante una dinámica caótica conocida. La aplicación a Bitcoin muestra que parte de ese flujo sigue siendo útil cuando los datos son reales, ruidosos y heterocedásticos.

Otro elemento diferencial es la comparación explícita con series barajadas, series sustitutas y modelos de referencia. Estos controles ayudan a no confundir distribución marginal, autocorrelación lineal o persistencia de volatilidad con caos determinista. También se incorpora HAR-logRV como modelo práctico de cierre, porque la volatilidad financiera presenta memoria a varias escalas y porque un modelo sencillo e interpretable puede ser más útil para una implementación final que un método más difícil de justificar.

Por último, el MVP web convierte parte del estudio en una herramienta demostrable. La aplicación no proporciona asesoramiento financiero, no predice la dirección del mercado y no demuestra caos. Su papel es mostrar que el procedimiento puede integrarse en un sistema autónomo capaz de cargar datos, calcular variables, ejecutar modelos y visualizar predicciones de volatilidad. Con este marco teórico quedan fijados los conceptos necesarios para interpretar los capítulos siguientes sin anticipar conclusiones fuertes sobre la serie de BTC.

Planificación, metodología de trabajo y costes

- 4.1– Organización general del proyecto**
- 4.2– Fases principales del trabajo**
- 4.3– Planificación temporal**
- 4.4– Distribución del esfuerzo**
- 4.5– Herramientas de seguimiento y desarrollo**
- 4.6– Estimación de costes**
- 4.7– Desviaciones respecto a la planificación inicial**
- 4.8– Lecciones aprendidas durante el desarrollo**

Análisis de requisitos

- 5.1– Requisitos generales del sistema**
- 5.2– Requisitos conceptuales y de comunicación**
- 5.3– Requisitos de datos**
- 5.4– Requisitos metodológicos**
- 5.5– Requisitos de la comprobación sintética**
- 5.6– Requisitos funcionales del procedimiento de análisis**
- 5.7– Requisitos funcionales del MVP web**
- 5.8– Requisitos no funcionales**
- 5.9– Criterios de validación**

Diseño de la solución

- 6.1– Visión general de la solución propuesta**
- 6.2– Arquitectura global del sistema**
- 6.3– Diseño del procedimiento metodológico**
- 6.4– Diseño de la comprobación sintética**
- 6.5– Diseño de la aplicación empírica a Bitcoin**
- 6.6– Diseño del flujo de datos**
- 6.7– Diseño experimental y separación temporal**
- 6.8– Diseño de la arquitectura del MVP web**
- 6.9– Variables de entrada, salida y transformación**
- 6.10– Organización del repositorio**

Implementación del procedimiento de análisis

7.1– Estructura general del procedimiento

El procedimiento implementado se organiza como una cadena reproducible de análisis. Primero se definen y explican las herramientas; después se comprueba su comportamiento en un sistema sintético conocido, el mapa logístico; finalmente se aplican a una serie financiera real de volatilidad realizada de Bitcoin. Esta separación es importante porque el mapa logístico permite verificar que la metodología responde ante una dinámica caótica controlada, mientras que Bitcoin sirve para estudiar qué ocurre cuando la señal aparece mezclada con ruido, persistencia, heterocedasticidad y cambios de régimen.

7.2– Entorno de desarrollo y herramientas utilizadas

7.3– Obtención y validación inicial de los datos

El dato bruto procede de los ficheros mensuales de klines de Binance Spot para el par BTCUSDT con frecuencia de cinco minutos. Los archivos se descargan en formato comprimido desde la ruta pública de Binance Data Vision, con nombres del tipo `BTCUSDT-5m-2024-01.zip`, y se almacenan en `data/raw/`. El script `build_btc_5m_clean.py` lee todos los `.zip`, extrae los CSV internos sin cabecera, normaliza las columnas de Binance y genera el fichero limpio `btc_5m_clean.csv`.

La Fase 0 valida este CSV antes de construir cualquier variable derivada: columnas esperadas, rango temporal, frecuencia exacta de cinco minutos, duplicados, huecos, nulos, conversiones numéricas, precios positivos y consistencia OHLC. Esta validación es necesaria para que las fases posteriores no interpreten errores de adquisición como estructura dinámica.

7.4– Construcción de variables y medidas de volatilidad**7.5– Visualización inicial y estadísticos descriptivos****7.6– Análisis de estacionariedad****7.7– Análisis de autocorrelación y espectro****7.8– Gráficos de recurrencia****7.9– Filtrado lineal mediante modelos autorregresivos****7.10– Contrastes de no linealidad****7.11– Reconstrucción del espacio de estados****7.12– Cuantificación de la dinámica reconstruida****7.13– Contrastes con barajado y datos subrogados****7.14– Predicción local de volatilidad****7.15– Experimentos de robustez y configuraciones alternativas****7.16– Comprobación sintética con mapa logístico**

La Fase 13 replica el procedimiento sobre un mapa logístico con parámetro caótico conocido. Esta fase no utiliza datos de Bitcoin, sino una serie sintética que permite comprobar si las herramientas de reconstrucción, cuantificación y predicción local responden cuando existe una dinámica no lineal controlada. El contraste es importante para la memoria: si el procedimiento detecta estructura en el mapa logístico pero ofrece resultados más ambiguos en BTC, la conclusión prudente no se debe a un fallo directo de implementación, sino a la naturaleza financiera y ruidosa de la serie real.

7.17– Modelo HAR-logRV y exportación al MVP

La Fase 14 introduce un modelo HAR-logRV compacto como cierre predictivo operativo. El modelo estima la volatilidad futura a una hora a partir de tres memorias de volatilidad realizada: 1 hora, 4 horas y 1 día. Sus coeficientes se ajustan solo en train y se evalúan en validation y test sin recalibración. Además, el modelo se exporta como artefacto JSON para que el MVP web pueda ejecutarlo sin importar código del repositorio técnico.

7.18– Resultado final de la validación del modelo

Resultados y discusión

8.1– Resultados de la comprobación sintética

El mapa logístico confirma que el procedimiento detecta estructura cuando la dinámica subyacente es determinista, no lineal y conocida. En la serie limpia aparece una reconstrucción geométrica más nítida que en Bitcoin, una divergencia positiva de trayectorias y una predicción local claramente superior a las referencias lineales. En términos de error, el mejor kNN reduce el RMSE de la referencia $AR(0)$ /media de 0,3565 a 0,0982 en la serie limpia. Al añadir ruido, la reconstrucción se difumina y las estimaciones de Lyapunov pierden nitidez, aunque la predicción local sigue siendo competitiva.

8.2– Resultados de la aplicación empírica a Bitcoin**8.3– Resultados de la caracterización inicial****8.4– Resultados del filtrado lineal****8.5– Indicios de dependencia no lineal****8.6– Resultados de la reconstrucción del espacio de estados****8.7– Resultados de cuantificación dinámica****8.8– Resultados de predicción local****8.9– Comparación con modelos de referencia****8.10– Comparación entre configuraciones alternativas****8.11– Comparación final con HAR-logRV**

La comparación final incorpora HAR-logRV como modelo práctico de memoria multiescala. En la muestra test comparable de 5000 puntos, HAR-logRV obtiene un RMSE de 0,8608, frente a 0,8641 de AR(49) y 0,8765 del kNN local con $\tau = 137$, $m = 5$ y $k = 200$. La mejora frente a AR(49) es pequeña, aproximadamente un 0,4 %, por lo que no debe presentarse como una ruptura fuerte respecto al benchmark lineal. Su interés principal está en que combina buen rendimiento, bajo coste computacional, interpretabilidad y facilidad de exportación al MVP.

Este resultado también matiza la lectura de las fases de reconstrucción: el kNN confirma cierta utilidad predictiva de la estructura local, pero en BTC la persistencia multiescala de la volatilidad queda mejor resumida por un modelo HAR simple. Por tanto, HAR-logRV se interpreta como cierre práctico del estudio, no como evidencia adicional de caos determinista.

8.12– Discusión: indicios frente a demostración de caos determinista**8.13– Interpretación global de los resultados**

Implementación del MVP web

9.1– Objetivo del prototipo web

9.2– Funcionalidades implementadas

9.3– Arquitectura de la aplicación

9.4– Integración del modelo validado

9.5– Interfaz de usuario

9.6– Flujo de uso de la aplicación

9.7– Limitaciones del MVP

Pruebas y verificación

- 10.1– Estrategia general de pruebas**
- 10.2– Validación de datos y preprocesado**
- 10.3– Validación de la construcción de variables**
- 10.4– Validación de los scripts del procedimiento**
- 10.5– Validación de la separación train/test**
- 10.6– Validación de resultados experimentales**
- 10.7– Pruebas del MVP web**
- 10.8– Métricas utilizadas**
- 10.9– Resumen de incidencias y correcciones**

Manual de usuario

- 11.1– Objetivo de la herramienta**
- 11.2– Requisitos para la ejecución**
- 11.3– Puesta en marcha del sistema**
- 11.4– Ejecución del procedimiento de análisis**
- 11.5– Uso del MVP web**
- 11.6– Interpretación básica de las salidas**
- 11.7– Generación de figuras, tablas e informes**

Conclusiones y desarrollos futuros

12.1– Conclusiones generales

12.2– Conclusiones sobre la metodología desarrollada

12.3– Conclusiones sobre el mapa logístico

12.4– Conclusiones sobre la aplicación a Bitcoin

12.5– Conclusiones sobre la utilidad predictiva

12.6– Conclusiones sobre el MVP web

12.7– Limitaciones finales del trabajo

12.8– Desarrollos futuros

ANEXO A

Glosario de conceptos técnicos

ANEXO B

Relación entre fases del proyecto y capítulos de la tesis de referencia

ANEXO C

Detalle completo de las fases de validación

ANEXO D

Tablas de resultados extendidas

ANEXO E

Manual técnico de instalación

ANEXO **F**

Estructura completa del repositorio

Referencias

- Abarbanel, H. D. I. (1996). *Analysis of observed chaotic data*. New York: Springer. doi: 10.1007/978-1-4612-0763-4
- Andersen, T. G., Bollerslev, T., Diebold, F. X., y Labys, P. (2003). Modeling and forecasting realized volatility. *Econometrica*, 71(2), 579–625. doi: 10.1111/1468-0262.00418
- Bandt, C., y Pompe, B. (2002). Permutation entropy: A natural complexity measure for time series. *Physical Review Letters*, 88(17), 174102. doi: 10.1103/PhysRevLett.88.174102
- Barndorff-Nielsen, O. E., y Shephard, N. (2002). Econometric analysis of realized volatility and its use in estimating stochastic volatility models. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 64(2), 253–280. doi: 10.1111/1467-9868.00336
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., y Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5.^a ed.). Hoboken, NJ: Wiley.
- Brock, W. A., Dechert, W. D., Scheinkman, J. A., y LeBaron, B. (1996). A test for independence based on the correlation dimension. *Econometric Reviews*, 15(3), 197–235. doi: 10.1080/07474939608800353
- Brockwell, P. J., y Davis, R. A. (2002). *Introduction to time series and forecasting* (2.^a ed.). New York: Springer. doi: 10.1007/b97391
- Cao, L. (1997). Practical method for determining the minimum embedding dimension of a scalar time series. *Physica D: Nonlinear Phenomena*, 110(1–2), 43–50. doi: 10.1016/S0167-2789(97)00118-8
- Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196. doi: 10.1093/jjfinec/nbp001
- Dickey, D. A., y Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366), 427–431. doi: 10.1080/01621459.1979.10482531
- Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of united kingdom inflation. *Econometrica*, 50(4), 987–1007. doi: 10.2307/1912773
- Farmer, J. D., y Sidorowich, J. J. (1987). Predicting chaotic time series. *Physical Review Letters*, 59(8), 845–848. doi: 10.1103/PhysRevLett.59.845
- Fraser, A. M., y Swinney, H. L. (1986). Independent coordinates for strange attractors from mutual information. *Physical Review A*, 33(2), 1134–1140. doi: 10.1103/PhysRevA.33.1134
- Grassberger, P., y Procaccia, I. (1983). Measuring the strangeness of strange attractors. *Physica D: Nonlinear Phenomena*, 9(1–2), 189–208. doi: 10.1016/0167-2789(83)90298-1
- Kantz, H., y Schreiber, T. (2003). *Nonlinear time series analysis* (2.^a ed.). Cambridge University Press. doi: 10.1017/CBO9780511755798
- Kennel, M. B., Brown, R., y Abarbanel, H. D. I. (1992). Determining embedding dimension for phase-space reconstruction using a geometrical construction. *Physical Review A*, 45(6), 3403–3411. doi: 10.1103/PhysRevA.45.3403
- Kwiatkowski, D., Phillips, P. C. B., Schmidt, P., y Shin, Y. (1992). Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, 54(1–3), 159–

178. doi: 10.1016/0304-4076(92)90104-Y
- Ljung, G. M., y Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303. doi: 10.1093/biomet/65.2.297
- May, R. M. (1976). Simple mathematical models with very complicated dynamics. *Nature*, 261(5560), 459–467. doi: 10.1038/261459a0
- Müller, U. A., Dacorogna, M. M., Davé, R. D., Olsen, R. B., Pictet, O. V., y von Weizsäcker, J. E. (1997). Volatilities of different time resolutions: Analyzing the dynamics of market components. *Journal of Empirical Finance*, 4(2–3), 213–239. doi: 10.1016/S0927-5398(97)00007-8
- Olmedo Fernández, E. (2001). *Análisis de series temporales en el contexto de la economía dinámica no lineal y caótica. aplicación a datos de la economía española* (Tesis Doctoral no publicada). Universidad de Sevilla, Sevilla.
- Priestley, M. B. (1981). *Spectral analysis and time series*. London: Academic Press.
- Rosenstein, M. T., Collins, J. J., y De Luca, C. J. (1993). A practical method for calculating largest lyapunov exponents from small data sets. *Physica D: Nonlinear Phenomena*, 65(1–2), 117–134. doi: 10.1016/0167-2789(93)90009-P
- Schreiber, T., y Schmitz, A. (2000). Surrogate time series. *Physica D: Nonlinear Phenomena*, 142(3–4), 346–382. doi: 10.1016/S0167-2789(00)00043-9
- Takens, F. (1981). Detecting strange attractors in turbulence. En D. Rand y L.-S. Young (Eds.), *Dynamical systems and turbulence, warwick 1980* (Vol. 898, pp. 366–381). Berlin, Heidelberg: Springer. doi: 10.1007/BFb0091924
- Theiler, J. (1986). Spurious dimension from correlation algorithms applied to limited time-series data. *Physical Review A*, 34(3), 2427–2432. doi: 10.1103/PhysRevA.34.2427
- Theiler, J., Eubank, S., Longtin, A., Galdrikian, B., y Farmer, J. D. (1992). Testing for nonlinearity in time series: The method of surrogate data. *Physica D: Nonlinear Phenomena*, 58(1–4), 77–94. doi: 10.1016/0167-2789(92)90102-S